Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Inteligencia Artificial

Auratio: Mejora Integral de la Estética Visual Mediante el Aprendizaje de Reglas Fotográficas y Críticos Perceptuales de Color

Trabajo Fin de Estudios

presentado por: David Gil Bautista

Dirigido por: Abdelmalik Moujahid Moujahid

Ciudad:Granada, España

Fecha: 4 de febrero de 2026

Índice de Contenidos

Resumen VI

Abstract VII

1. Introducción 1

1.1. Motivación . . . 1

1.2. Planteamiento del trabajo . . . 3

1.3. Estructura de la memoria . . . 4

2. Contexto y estado del arte 5

2.1. Fundamentos teóricos de la fotografía computacional . . . 5

2.1.1. Espacios de color y percepción visual . . . 5

2.1.2. Estética Computacional . . . 6

2.2. Contexto del problema . . . 6

2.3. Trabajos relacionados . . . 7

2.3.1. Mejora de imagen basada en redes neuronales y aprendizaje profundo 7

2.3.2. Composición fotográfica y análisis de reglas estéticas . . . 10

2.4. Conclusión del estado del arte . . . 13

3. Objetivos concretos y metodología de trabajo 14

3.1. Objetivo general . . . 14

3.2. Objetivos específicos . . . 14

3.3. Metodología de trabajo . . . 15

3.3.1. Análisis y preparación del conjunto de datos . . . 15

3.3.2. Diseño de la arquitectura del modelo . . . 18

4. Desarrollo específico de la contribución 22

4.1. Herramientas y *frameworks* . . . 22

4.2. Entorno de cómputo . . . 22

4.3. Preprocesamiento de datos y generación de pares sintéticos . . . 23

4.3.1. Módulo de colorimetría (LUTNet) . . . 23

4.3.2. Módulo de composición . . . 25

4.4. Arquitectura de la solución . . . 27

4.4.1. Módulo de colorimetría por curvas 27
4.4.2. Módulo de composición 33
4.5. Análisis de Resultados 38
4.5.1. Métricas de entrenamiento del módulo de colorimetría 38
4.5.2. Métricas de entrenamiento del módulo de composición 39
4.5.3. Métricas de inferencia y calidad perceptual 40
4.5.4. Métricas de evaluación subjetiva: Mean Opinion Score (MOS) 43
4.5.5. Eficiencia temporal (*Throughput*) 45
4.5.6. Análisis visual de los resultados 45

5. Conclusiones y trabajo futuro **50**
5.1. Conclusiones del proyecto 50
5.2. Líneas de trabajo futuro 51
5.2.1. Optimización y eficiencia computacional 51
5.2.2. Expansión y validación del dominio estético 52
5.2.3. Aplicación a secuencias de vídeo 52
Referencias 53

A. Apendices **56**

Índice de Ilustraciones

2.1. Estructura de la red UEGAN 8

2.2. Estructura de la red EnhanceGAN 9

2.3. Estructura de la red CURL 10

2.4. Arquitectura de la red NamedCurves. En primer lugar, se extraen mapas de características convolucionales utilizando 4 bloques *Conv-ReLU*. A continuación, se concatena la denominación de colores y se pasa a través de 4 bloques *Conv-ReLU-MaxPooling* y una capa final *AveragePooling*. La salida del módulo son los incrementos de los puntos de control no normalizados. . 11

2.5. Arquitectura de la red SACNet. A partir de una imagen de entrada y la selección del usuario, se emplea SSD (*Single shot multibox object detector*) para generar la máscara del sujeto, cuya concatenación con la imagen original sirve de entrada para SACNet. El proceso se divide en tres fases: primero, un módulo de regresión extrae características y genera un mapa de puntuación de candidatos, seleccionando y aplicando ROIalign a los 256 puntos de anclaje con mayor relevancia; posteriormente, un módulo de regresión de ventana de recorte calcula los *offsets* de *fine-tuning* para dichas cajas, repitiendo el proceso de ROIalign sobre el mapa de características; finalmente, un tercer módulo determina la puntuación de composición definitiva para cada ventana ajustada. En la esquina superior derecha se ilustra un ejemplo de este proceso de ajuste fino de un *anchor box*. 12

3.1. Ejemplo de imágenes en el *dataset* Unsplash. 17

4.1. Esquema de generación del conjunto de datos de entrenamiento para el módulo de composición. 26

4.2. Arquitectura del módulo de colorimetría. Para el codificador se usa de base una ResNet-18 que extrae características semánticas de la imagen en la que se sustituye la última capa FC por una capa identidad. Adicionalmente, se extrae un vector de estadísticas globales de color mediante la red VGG16. El cabezal final de regresión toma estas entradas y predice un vector de desplazamientos (Δ) sobre curvas de identidad para ajustes tonales en los canales RGB y brillo. 28
4.3. Arquitectura del módulo de composición. Para el codificador se usa de base una ResNet-50 con los pesos congelados en los primeros bloques. Esta red permite extraer características muy complejas de la imagen para finalmente predecir un vector de regresión con los parámetros que permiten el recorte ideal. 34
4.4. Evolución de la pérdida en la fase 1 de entrenamiento del módulo de colorimetría. 39
4.5. Evolución de la pérdida en la fase 2 de entrenamiento del módulo de colorimetría. 40
4.6. Evolución de la pérdida en la fase de entrenamiento del módulo de composición. 41
4.7. Resultado del *pipeline* de inferencia completo y representación visual de las guías usadas como pérdidas en el módulo de composición. En verde regla de los tercios, en rojo proporción áurea y en azul simetría horizontal y vertical. 47
4.8. Comparación visual entre la imagen de entrada y el resultado final. La Figura a muestra la imagen capturada y la Figura b el resultado optimizado. 48
4.9. Comparación visual entre la imagen de entrada y el resultado final. La Figura a muestra la imagen capturada y la Figura b el resultado optimizado. 49

Índice de Tablas

3.1. Características principales del *dataset* Unsplash (Versión Lite) 16

4.1. *Frameworks* de aprendizaje profundo 22
4.2. Librerías para procesamiento de imágenes y análisis de datos 23
4.3. Resumen de componentes y dimensiones del módulo de colorimetría 28
4.4. Desglose de las funciones de pérdida individuales de la red de mejora de colorimetría basada en curvas 30
4.5. Pesos de las funciones de pérdida del módulo de colorimetría en la fase 1. . 32
4.6. Pesos de las funciones de pérdida del módulo de colorimetría en la fase 2. . 33
4.7. Funciones de pérdida de la red de mejora de composición. 36
4.8. Pesos de las funciones de pérdida del módulo de composición. 38
4.9. Resultados de la métricas BRISQUE y NIQE en los distintos conjuntos de datos de salida. 42
4.10. Resultados de la evaluación subjetiva MOS para las diferentes etapas del pipeline. 44

Resumen

La edición fotográfica profesional es un proceso complejo que exige tanto un ojo artístico para la composición como un dominio técnico de la ciencia del color. A pesar de los avances en el aprendizaje profundo, la ausencia de una herramienta totalmente automática capaz de editar imágenes RAW de manera integral sigue siendo un desafío. Este trabajo propone un sistema de dos etapas diseñado para transformar entradas RAW en fotografías optimizadas estéticamente sin intervención humana. El primer módulo, una red para recorte óptico (CropNet), resuelve el problema del encuadre mediante una arquitectura de red neuronal residual de 50 capas (ResNet-50) adaptada. Este modelo predice el recorte óptimo, respetando reglas fotográficas fundamentales como la regla de los tercios. El segundo módulo, una red para corrección mediante tablas de búsqueda (LUTNet), realiza la mejora colorimétrica. Utiliza un codificador basado en ResNet-18 y un conjunto de estadísticas globales para predecir y aplicar ajustes tonales de alta precisión a través de un vector de curvas. Los resultados experimentales demuestran que el flujo de trabajo produce imágenes que no solo presentan una composición equilibrada, sino también una colorimetría superior, mejorando las capacidades de las herramientas de filtrado global existentes.

Palabras Clave: edición fotográfica, redes neuronales, aprendizaje adversarial, aprendizaje auto-supervisado

Abstract

Professional photo editing is a complex process that requires both an artistic eye for composition and technical mastery of color science. Despite advances in deep learning, the absence of a fully automatic tool capable of comprehensively editing RAW images remains a challenge. This work proposes a two-stage system designed to transform RAW inputs into aesthetically optimized photographs without human intervention. The first module, a network for optical cropping (CropNet), solves the framing problem using an adapted 50-layer residual neural network architecture (ResNet-50). This model predicts the optimal crop, respecting fundamental photographic rules such as the rule of thirds. The second module, a lookup table correction network (LUTNet), performs colorimetric enhancement. It uses a ResNet-18-based encoder and a set of global statistics to predict and apply high-precision tonal adjustments through a curve vector. Experimental results demonstrate that the workflow produces images that not only have a balanced composition but also superior colorimetry, improving on the capabilities of existing global filtering tools.

Keywords: photo editing, neural networks, adversarial learning, self-learning

David Gil Bautista
Máster en Inteligencia Artificial

1. Introducción

La fotografía digital se ha consolidado en la última década como una de las formas de comunicación más influyentes y ubicuas en la sociedad contemporánea. Plataformas globales como Instagram, TikTok o Pinterest no solo alojan contenido, sino que estructuran sus algoritmos y dinámicas sociales en torno a la producción y circulación masiva de imágenes (Highfield y Leaver, 2016). Esta transformación cultural ha dado lugar a lo que diversos autores denominan la "cultura de la visibilidad", un paradigma donde la identidad personal, la narrativa de marca y el reconocimiento social se construyen y validan a través de la imagen (Hand, 2017; Mejova, Weber, y Fernandes Silva, 2018).

En este contexto, la cámara fotográfica ha dejado de ser una herramienta exclusiva de profesionales para convertirse en una extensión del dispositivo móvil presente en el bolsillo de miles de millones de usuarios. Sin embargo, a pesar de la sofisticación del *hardware* ,con sensores de gran tamaño y ópticas avanzadas, existe una brecha técnica y artística significativa entre el acto de capturar una imagen y la obtención de un resultado visualmente profesional.

La democratización del *hardware* no ha traído consigo una democratización del conocimiento estético. Lograr una fotografía de alto nivel implica el dominio de dos dominios críticos, complejos y a menudo tratados de forma aislada en la literatura técnica: la composición espacial (dónde mirar) y la corrección colorimétrica (cómo sentir lo que se mira). La ausencia de estas competencias en el usuario promedio resulta en un vasto océano de contenido digital que, aunque técnicamente nítido, carece de impacto visual y narrativa.

1.1. Motivación

El problema central que motiva este trabajo es la dificultad inherente que enfrentan los usuarios no expertos para obtener fotografías con una calidad estética equiparable a la de un editor humano profesional y la ausencia de herramientas que faciliten este trabajo logrando un resultado de alta calidad. Aunque los dispositivos móviles actuales permiten capturas de alta resolución y rango dinámico (HDR), el proceso mental de "hacer una foto" termina para la mayoría de las personas en el instante del disparo.

Por el contrario, un fotógrafo profesional entiende la captura (el archivo RAW) solo como el lienzo inicial de un proceso creativo más amplio. Este proceso implica:

1. **Decisiones geométricas:** Aplicar principios de composición visual (Freeman, 2007) como la regla de los tercios, la proporción áurea o la gestión del espacio negativo para guiar el ojo del espectador.

2. **Decisiones cromáticas:** Realizar ajustes precisos de curvas de tono y colorimetría para establecer una atmósfera y una coherencia narrativa.

Si bien existen soluciones automatizadas en el mercado y en la literatura científica reciente (Lee y Kwon, 2021), estas presentan limitaciones fundamentales que impiden una experiencia de edición verdaderamente inteligente. Este proyecto busca superar tres barreras específicas:

- **Desconexión de procesos:** Las herramientas de edición comerciales y muchos modelos académicos tratan el recorte (*cropping*) y el tratamiento del color como tareas estancas e independientes. En la práctica profesional, estos elementos son simbióticos: un reencuadre puede alterar el histograma de la imagen, requiriendo un ajuste de color diferente para mantener el equilibrio visual.

- **Rigidez de las reglas heurísticas:** Los algoritmos convencionales de auto-recorte suelen basarse en heurísticas simples, como la detección de rostros o la centralización del objeto más grande. Estos enfoques ignoran reglas estéticas complejas y sutiles, como el equilibrio de pesos visuales, las simetrías dinámicas o la alineación con líneas arquitectónicas, resultando en composiciones monótonas.

- **Dependencia del contexto global y falta de "intención":** Las correcciones automáticas tradicionales (como el botón "*Auto-Level*" o los filtros LUT genéricos) se basan puramente en estadísticas globales de la imagen. Esto genera resultados técnicamente correctos (buena exposición media), pero estéticamente planos, carentes de la intención dramática o artística que proporcionan las curvas de color personalizadas por un humano.

Desde una perspectiva técnica, el problema se define como la necesidad de diseñar un sistema inteligente capaz de mapear una imagen de entrada I_{raw} a una imagen de salida optimizada I_{opt}, mediante la predicción simultánea de un vector de recorte geométrico ($4D$) y un conjunto de curvas de ajuste de color ($51D$). La dificultad reside en que "una buena fotografía" es un concepto altamente subjetivo y difícil de cuantificar mediante funciones

de pérdida tradicionales (como el Error Cuadrático Medio). Traducir esa subjetividad a parámetros matemáticos optimizables requiere arquitecturas de aprendizaje profundo capaces de extraer tanto características semánticas de alto nivel ("¿qué hay en la foto?") como estadísticas granulares del píxel ("¿cómo es la luz?").

Resolver este problema no solo representa un desafío académico en el campo de la visión por computador, sino que tiene una implicación social directa: democratizar la capacidad de creación visual, permitiendo que cualquier usuario, independientemente de su formación artística, pueda expresarse visualmente con calidad profesional.

1.2. Planteamiento del trabajo

Para abordar la problemática descrita, este Trabajo de Fin de Estudios propone el desarrollo de un sistema de mejora fotográfica integral basado en Aprendizaje Profundo (*Deep Learning*). La hipótesis subyacente es que la estética fotográfica no es un fenómeno monolítico, sino la suma de la geometría y la colorimetría, y que ambas pueden ser modeladas eficazmente mediante redes neuronales especializadas que operen en conjunto.

La contribución original de este trabajo reside en la creación de un flujo de trabajo *end-to-end* que utiliza una arquitectura desacoplada para maximizar el rendimiento en cada sub-tarea. A diferencia de otros enfoques que utilizan una única red "caja negra" para todo el proceso (*image-to-image translation*), esta propuesta de dualidad de redes permite una especialización mayor y más interpretable:

- **CropNet (Enfoque Semántico):** Se basa en la premisa de que para encuadrar bien, hay que entender qué se está mirando. Utiliza una base ResNet-50 pre-entrenada para extraer características profundas que permiten identificar sujetos principales y líneas de fuerza.

- **LUTNet (Enfoque Estadístico-Visual):** Prioriza la fidelidad del color y la eficiencia. En lugar de generar píxeles desde cero (lo cual introduce artefactos), predice los parámetros de una Tabla de Búsqueda (LUT) o curvas de ajuste, asegurando que la textura original de la imagen se mantenga intacta.

Esta metodología híbrida busca emular el flujo de trabajo de un editor humano, que primero selecciona el mejor encuadre para eliminar distracciones y posteriormente trabaja el color para potenciar el mensaje visual.

1.3. Estructura de la memoria

El presente trabajo se organiza en cinco capítulos principales:

- **Introducción**: se expone el problema y la motivación del proyecto, así como el planteamiento general de la propuesta.
- **Contexto y estado del arte**: se revisan los fundamentos teóricos y los trabajos previos relacionados con la edición automática de imágenes, la mejora de colorimetría y las técnicas de composición fotográfica mediante inteligencia artificial.
- **Objetivos concretos y metodología de trabajo**: se presentan los objetivos específicos que persigue el proyecto y se describe la metodología empleada, incluyendo el diseño del sistema, los modelos de aprendizaje profundo y el proceso de desarrollo software.
- **Desarrollo específico de la contribución**: se detalla la implementación del sistema, la arquitectura propuesta, los experimentos realizados y los resultados obtenidos.
- **Conclusiones y trabajo futuro**: se resumen los principales hallazgos del trabajo, se señalan sus limitaciones y se plantean posibles líneas de investigación y mejora.

2. Contexto y estado del arte

El presente capítulo tiene como finalidad situar el proyecto dentro del marco teórico y tecnológico actual, analizando los fundamentos que sustentan su desarrollo y las principales líneas de investigación relacionadas. En primer lugar, se contextualiza el problema que motiva la propuesta, abordando las limitaciones actuales en la edición fotográfica automática y los desafíos que plantea la incorporación de criterios estéticos en sistemas inteligentes. A continuación, se revisan los trabajos más relevantes en el ámbito de la mejora de imágenes mediante redes neuronales profundas y el análisis compositivo. Este análisis permite identificar las carencias de las soluciones existentes y justificar la necesidad de un enfoque integral como el que se plantea en este trabajo.

En primer lugar, se establecen los fundamentos teóricos sobre la percepción del color y la estética computacional. Posteriormente, se contextualiza el problema que motiva esta propuesta, abordando las limitaciones inherentes a la captura de imágenes en dispositivos no profesionales. A continuación, se realiza una revisión exhaustiva de la literatura, dividiendo el estado del arte en dos grandes bloques: la mejora técnica basada en redes neuronales y aprendizaje profundo y el análisis compositivo. Finalmente, se discuten los conjuntos de datos que han hecho posible estos avances. Este análisis crítico permitirá identificar los vacíos tecnológicos y justificar la necesidad del enfoque híbrido planteado en este trabajo.

2.1. Fundamentos teóricos de la fotografía computacional

Para comprender los desafíos de la edición automática, es necesario entender primero cómo se representa la información visual y cómo esta representación difiere de la percepción humana.

2.1.1. Espacios de color y percepción visual

La mayoría de las imágenes digitales se capturan y visualizan en el espacio de color RGB (Rojo, Verde, Azul). Sin embargo, este espacio no es perceptualmente uniforme; es decir, la distancia euclidiana entre dos colores en el espacio RGB no se corresponde necesariamente con la diferencia percibida por el ojo humano.

En el ámbito de la mejora fotográfica mediante IA, es frecuente trabajar en espacios de

color alternativos como CIELAB ($L^*a^*b^*$) o HSV. El espacio CIELAB, por ejemplo, separa la luminancia (L^*) de la información cromática (a^* y b^*). Esto es crucial para modelos de aprendizaje profundo, ya que permite ajustar el contraste y la exposición (modificando L^*) sin alterar la saturación o el tono de los colores, un error común en los filtros lineales simples. Las redes neuronales modernas a menudo incorporan pérdidas perceptuales que operan en estos espacios para garantizar que las mejoras sean agradables a la vista y no solo matemáticamente correctas.

2.1.2. Estética Computacional

La estética computacional es la rama de la visión por computador que intenta cuantificar la belleza. A diferencia de la calidad técnica (que mide ruido, nitidez o artefactos de compresión), la calidad estética es subjetiva e incluye factores como la regla de los tercios, la armonía de color, la profundidad de campo y el contenido emocional. Modelar matemáticamente esta subjetividad es el principal reto del campo, requiriendo algoritmos que no solo vean píxeles, sino que entiendan el contexto semántico de la escena.

2.2. Contexto del problema

En la era de la fotografía digital, la creación de contenido visual se ha democratizado de forma masiva gracias a la accesibilidad de cámaras en dispositivos móviles y plataformas como Instagram, Pinterest o Unsplash. Sin embargo, aunque la capacidad técnica para capturar imágenes ha mejorado, la calidad estética y compositiva de muchas fotografías sigue dependiendo en gran medida de la experiencia del usuario tanto en la toma de la imagen como en la posible edición posterior. Los fotógrafos profesionales aplican criterios técnicos y artísticos como la gestión del color, el equilibrio de luces y sombras o las reglas de composición. El uso de estas técnicas implica una formación previa y una experiencia necesaria de la que carece el usuario promedio de dichas plataformas.

Actualmente, el mercado ofrece herramientas de edición como automática o semiautomática, como las implementadas en aplicaciones comerciales (Adobe Lightroom, Snapseed, VSCO), que mejoran parámetros técnicos como el contraste, la saturación o la exposición de manera rápida y sencilla (Adobe HelpX, 2025; Snapseed QRCodes, 2025; VSCO Support, 2025). No obstante, la mayoría de sus funciones automáticas operan bajo la lógica de "filtros globales" (LUTs) predefinidos o ajustes genéricos (Reddit: r/snapseed, 2025; Red-

dit: r/vsco, 2025; Madgicx Blog, 2025) que se aplican uniformemente a toda la imagen, sin tener en cuenta el contenido semántico ni la estructura de la escena. Esto plantea un reto para la inteligencia artificial: ¿Cómo puede un algoritmo aprender no solo a corregir errores estadísticos, sino a "entender" qué hace que una imagen sea visualmente atractiva?

Además, la edición profesional implica un proceso de toma de decisiones subjetivo y contextual, que no puede deducirse únicamente de la imagen final. Esto plantea un reto para la inteligencia artificial: cómo aprender no solo a corregir una imagen, sino a entender qué la hace visualmente atractiva. En este contexto surge la idea de implementar un sistema inteligente orientado a mejorar automáticamente fotografías amateur respetando principios estéticos y compositivos inspirados en la práctica profesional.

2.3. Trabajos relacionados

En los últimos años, la aplicación de modelos de inteligencia artificial a la edición y mejora de imágenes ha experimentado un crecimiento exponencial. La evolución de arquitecturas como las redes generativas adversarias (GANs) y, más recientemente, los modelos de difusión, ha permitido automatizar tareas que tradicionalmente requerían intervención manual intensiva. A continuación, se clasifica la literatura en dos categorías que convergen en este proyecto: mejora de imagen y composición.

2.3.1. Mejora de imagen basada en redes neuronales y aprendizaje profundo

Esta categoría engloba investigaciones centradas en optimizar la percepción visual global mediante ajustes de colorimetría, exposición, nitidez o rango dinámico. El objetivo común es transformar una imagen de baja calidad en una visualmente atractiva, superando las limitaciones de los filtros tradicionales.

Uno de los enfoques más completos en el aprendizaje no supervisado es la red UEGAN (*Unsupervised image Enhancement GAN*) (Ni, Yang, Wang, Ma, y Kwong, 2020). Su arquitectura destaca la implementación de un módulo de atención global (GAM), que opera en tres etapas: extracción de estadísticas globales por canal, cálculo de relaciones inter-canal mediante un perceptrón multicapa y fusión de características locales y globales. Para evitar la pérdida de información en cambios de resolución, incorpora un módulo de modulación que conecta el codificador y el decodificador de forma más compleja que una

U-Net tradicional. En cuanto a sus funciones de pérdida, emplea una pérdida de calidad basada en el discriminador relativista (*RaHingeGAN* (Jolicoeur-Martineau, 2018)) para empujar la distribución de la imagen hacia una estética profesional, y una pérdida de fidelidad calculada mediante la regularización L_2 entre mapas de características extraídos por una red VGG pre-entrenada, asegurando que el contenido semántico no se altere durante la edición. En la Figura 2.1 se puede apreciar la arquitectura de la red usada por los autores. Este enfoque demuestra que es posible aprender características estéticas sin supervisión directa, aunque tiende a centrarse en ajustes de bajo nivel sin considerar la estructura de la escena.

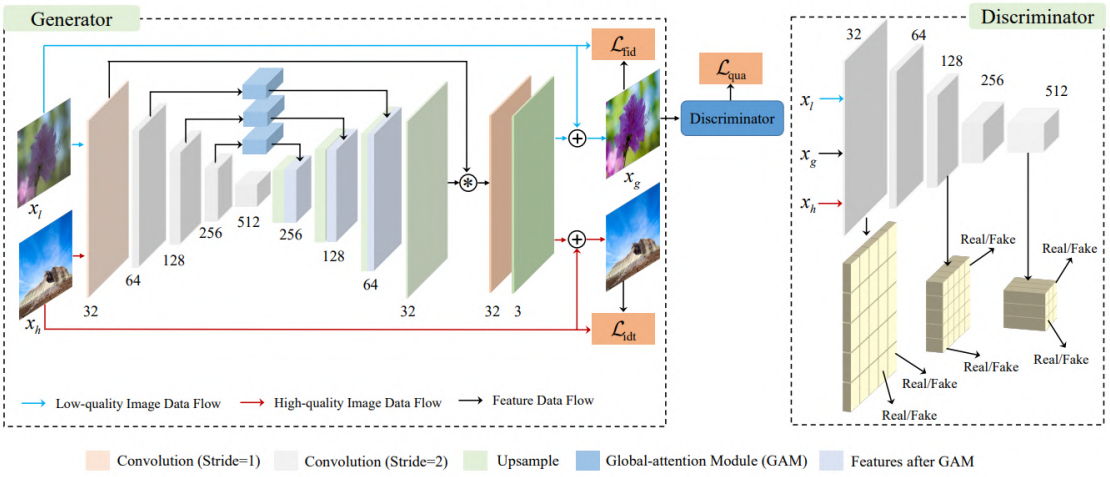

Figura 2.1: Estructura de la red UEGAN. El discriminador multiescala guía al generador para producir consistencia global sin perder detalles locales.

Fuente: (Ni y cols., 2020)

Otros autores han buscado integrar la percepción humana de la belleza directamente en el proceso de entrenamiento. El trabajo EnhanceGAN, presentado por (Deng, Loy, y Tang, 2017), utiliza una estructura de red adversaria de Wasserstein (W-GAN) (Arjovsky, Chintala, y Bottou, 2017) que implementa un discriminador que no solo evalúa la autenticidad de la imagen, sino también su atractivo estético basándose en conjuntos de datos puntuados por humanos (como AVA). En la Figura 2.2 se aprecia la arquitectura presentada por los autores. Su optimización se basa en una suma ponderada de la pérdida adversaria (L_{gan}), que garantiza el realismo visual, y una pérdida de reconstrucción de características (regularización), que minimiza la distancia semántica en el espacio de características de una VGG para preservar la estructura básica de la imagen original. El modelo aprende a priorizar transformaciones que resulten agradables al ojo humano pero, al igual que UE-

GAN, su mejora es principalmente estadística y carece de un entendimiento explícito de los elementos que componen la fotografía.

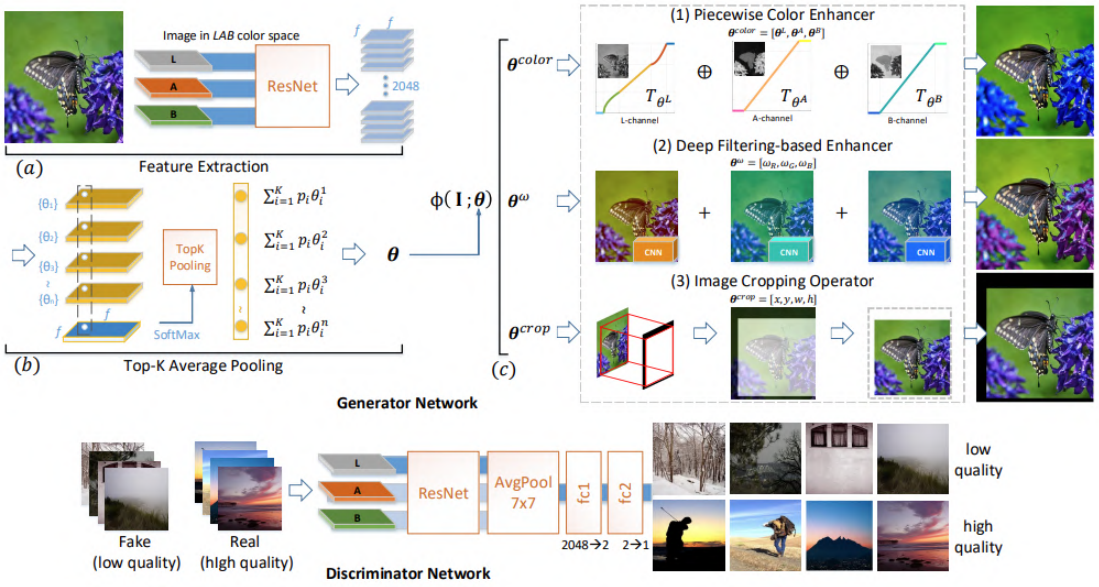

Figura 2.2: Estructura de la red EnhanceGAN. El módulo ResNet es el extractor de características; en este trabajo, los autores utilizan ResNet-101 [16] y se elimina la última capa de agrupación promedio y la capa FC final.

Fuente: (Deng y cols., 2017)

Buscando una mayor interpretabilidad en los ajustes, (Moran, McDonagh, y Slabaugh, 2020) introducen CURL (*CURve Layers*), un enfoque que combina la potencia del aprendizaje profundo con la interpretabilidad de las curvas de ajuste tradicionales. A diferencia de las redes neuronales densas que transforman píxeles de manera directa, CURL utiliza una arquitectura que podemos ver en 2.3 basada en redes convolucionales (CNN) para estimar de forma inteligente una serie de curvas de ajuste de color y luminosidad (como curvas de tono, saturación y valor). El funcionamiento del modelo se optimiza mediante un esquema de aprendizaje multietapa que ajusta globalmente la imagen en diferentes espacios de color, permitiendo mejorar el contraste y la fidelidad cromática sin introducir artefactos visuales. Esta metodología destaca por su eficiencia computacional, ya que la red no genera la imagen final píxel a píxel, sino que predice los parámetros de las curvas que luego se aplican de forma global, logrando resultados visualmente profesionales con un bajo coste de procesamiento.

En una línea similar de interpretabilidad semántica, NamedCurves (Serrano-Lozano, Herranz, Brown, y Vazquez-Corral, 2024) propone vincular regiones cromáticas con eti-

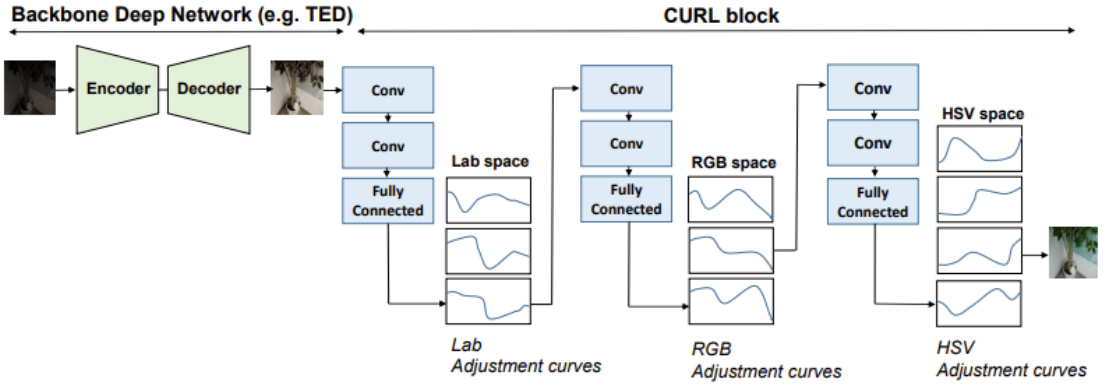

Figura 2.3: Estructura de la red CURL. Colocación del bloque CURL con respecto a un *backbone encoder-decoder*. El bloque CURL aprovecha las capas de curvas neuronales para realizar operaciones de refinamiento de imágenes inspiradas en artistas. La entrada a la red *backbone* es una imagen RAW y la salida del bloque CURL es una imagen RGB de alta calidad con el color y el brillo correctos.

Fuente: (Moran y cols., 2020)

quetas lingüísticas (p. ej., "azul cielo"), permitiendo que la red ajuste el color basándose en el contexto semántico y no solo en valores de píxeles. En la Figura 2.4 se aprecia la arquitectura de esta propuesta basada en curvas.

Finalmente, enfoques como StarEnhancer (Song, Qian, y Du, 2021) se centran en la eficiencia y el estilo, adaptando los ajustes en tiempo real a tipos de fotografía específicos (retrato, noche, paisaje). Gracias a la eficiencia y efectividad es un claro ejemplo de un buen enfoque para usar en dispositivos móviles, pero debido a la naturaleza de la solución estos modelos siguen operando bajo la lógica de filtros globales inteligentes y no resuelven el problema que se propone en este trabajo.

Síntesis del área: Si bien estos trabajos han logrado resultados sobresalientes en la calidad de la imagen a nivel de píxel y tono, la mayoría carece de una comprensión de la disposición espacial de los elementos. Mejoran "cómo se ve" la imagen, pero no "cómo está compuesta", lo que limita su capacidad para replicar el proceso de edición de un fotógrafo profesional completo.

2.3.2. Composición fotográfica y análisis de reglas estéticas

La segunda línea de investigación aborda el problema desde una perspectiva estructural, analizando cómo se distribuyen los elementos en el encuadre y si cumplen con reglas

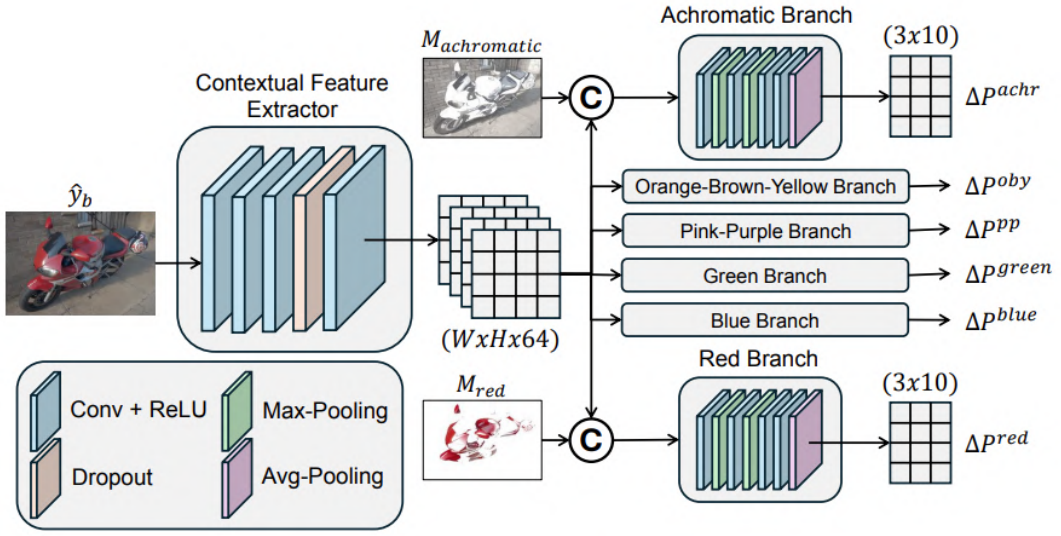

Figura 2.4: Arquitectura de la red NamedCurves. En primer lugar, se extraen mapas de características convolucionales utilizando 4 bloques *Conv-ReLU*. A continuación, se concatena la denominación de colores y se pasa a través de 4 bloques *Conv-ReLU-MaxPooling* y una capa final *AveragePooling*. La salida del módulo son los incrementos de los puntos de control no normalizados.

Fuente: (Serrano-Lozano y cols., 2024)

armónicas preestablecidas que favorecen el equilibrio visual de la imagen.

Uno de los enfoques clásicos es la detección algorítmica de reglas, como se presenta en (Mai, Le, Niu, y Liu, 2011) para la Regla de los Tercios. Los autores proponen algoritmos que segmentan los elementos clave como sujeto y horizonte y calculan su proximidad a las a las intersecciones del encuadre. Este tipo de análisis permite una evaluación objetiva de la composición, útil para sistemas de recomendación, aunque su rigidez impide adaptarse a estilos más creativos o complejos y no ofrece mejoras sobre la calidad de la imagen en sí.

Avanzando hacia el aprendizaje profundo, (Yang, Zhou, Cai, Zhang, y Zhang, 2022) proponen SACNet (*SubjectAware image Composition recommendation NETworks*), una red diseñada para recomendar composiciones basadas en el sujeto principal. En la Figura 2.5 se puede apreciar el diseño de la arquitectura de la red propuesta por los autores. A diferencia de las reglas rígidas, SACNet utiliza un detector de objetos semántico para identificar el foco de atención y una red de evaluación que estima el "atractivo compositivo" de múltiples recortes candidatos. El modelo se entrena para maximizar una puntuación estática de composición, sugiriendo reencuadres que potencian la jerarquía visual de la fo-

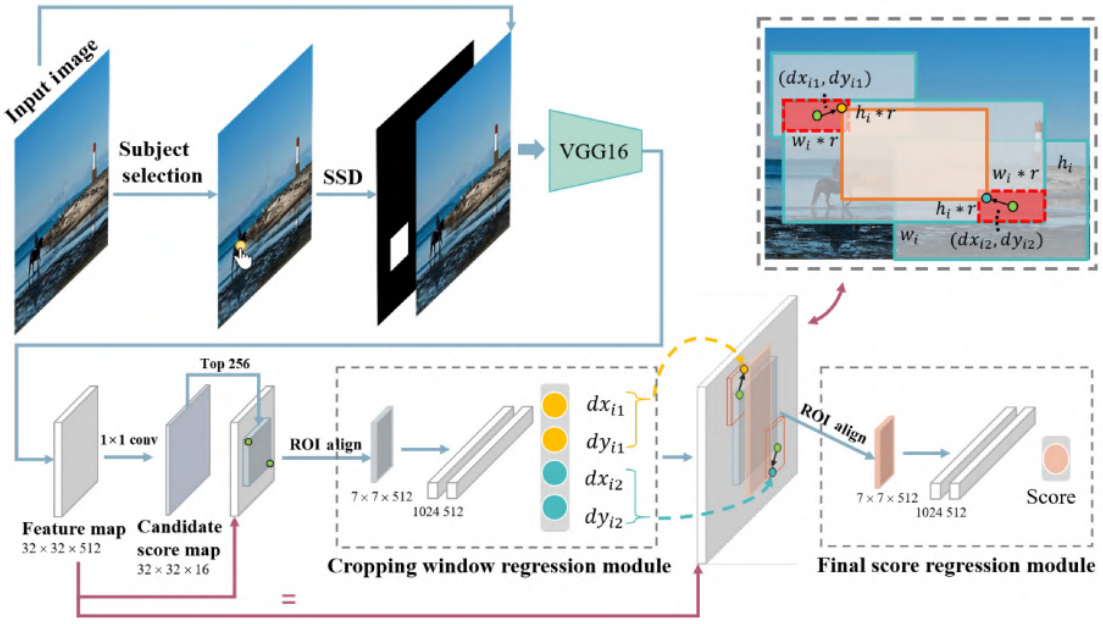

Figura 2.5: Arquitectura de la red SACNet. A partir de una imagen de entrada y la selección del usuario, se emplea SSD (*Single shot multibox object detector*) para generar la máscara del sujeto, cuya concatenación con la imagen original sirve de entrada para SACNet. El proceso se divide en tres fases: primero, un módulo de regresión extrae características y genera un mapa de puntuación de candidatos, seleccionando y aplicando ROIalign a los 256 puntos de anclaje con mayor relevancia; posteriormente, un módulo de regresión de ventana de recorte calcula los *offsets* de *fine-tuning* para dichas cajas, repitiendo el proceso de ROIalign sobre el mapa de características; finalmente, un tercer módulo determina la puntuación de composición definitiva para cada ventana ajustada. En la esquina superior derecha se ilustra un ejemplo de este proceso de ajuste fino de un *anchor box*.

Fuente (Yang y cols., 2022)

tografía. Aunque este trabajo introduce la necesaria comprensión de la estructura, se limita a la recomendación de reencuadres (*cropping*), dejando de lado la mejora colorimétrica o tonal.

Síntesis del área: Las soluciones actuales en composición tienden a funcionar de manera aislada: o analizan reglas geométricas o sugieren recortes, pero raramente se integran con los procesos de mejora de imagen descritos en la sección anterior.

2.4. Conclusión del estado del arte

El análisis de la literatura revela una dicotomía en las soluciones actuales. Por un lado, existen modelos de mejora de imagen muy avanzados capaces de ajustar color y exposición con gran fidelidad (UEGAN, CURL), pero que no son capaces de comprender la estructura de la foto. Por otro lado, existen herramientas de análisis compositivo (SACNet) que entienden la distribución espacial pero no intervienen en la calidad visual de la imagen.

El presente trabajo busca llenar este vacío proponiendo un sistema híbrido. La propuesta no se limita a mejorar la estética a nivel de píxel ni a reencuadrar basándose en reglas, sino que aspira a combinar ambos mundos: una mejora visual guiada tanto por la calidad de imagen como por una comprensión explícita de la composición fotográfica.

3. Objetivos concretos y metodología de trabajo

3.1. Objetivo general

El objetivo principal de este trabajo es desarrollar un sistema basado en aprendizaje profundo capaz de automatizar el flujo de edición fotográfica profesional, optimizando secuencialmente la composición espacial y la corrección colorimétrica de imágenes digitales. A diferencia de las herramientas de mejora global, este sistema busca emular la toma de decisiones humana mediante la regresión de parámetros geométricos y fotométricos basados en reglas estéticas de fotografía.

El objetivo general cumple los criterios SMART (Doran, 1981) de la siguiente forma:

1. Específico: se centra en la mejora estética y compositiva mediante modelos de aprendizaje profundo.
2. Medible: el rendimiento podrá evaluarse mediante métricas objetivas (NIQE, BRISQUE, FID) y subjetivas como tests de usuario.
3. Alcanzable: se basa en modelos existentes (Redes de regresión profunda, transferencia de aprendizaje, *composition-aware networks*) adaptados al contexto del proyecto.
4. Relevante: aborda una limitación actual de los modelos de mejora de imagen, que rara vez consideran la composición y el atractivo visual.
5. Temporal: el desarrollo y validación se plantean dentro del marco temporal del trabajo de fin de estudios.

3.2. Objetivos específicos

Para alcanzar el objetivo general, se proponen los siguientes hitos técnicos siguiendo la lógica del sistema diseñado:

- **OE1:** Análisis y fundamentación: Investigar el estado del arte en composición automática y mejora de color, analizando el uso de arquitecturas *backbone* (ResNet) y funciones de pérdida orientadas a la estética.

- **OE2:** Generación de un *dataset* sintético mediante modelos de difusión: Desarrollar un pipeline de preparación de datos que utilice técnicas de outpainting mediante modelos de difusión para expandir las regiones periféricas de imágenes profesionales. El objetivo es crear pares de entrenamiento donde la imagen expandida represente una composición subóptima y el recorte original actúe como el ground truth estético.

- **OE3:** Desarrollo del módulo de composición (*CropNet*): Diseñar e implementar una arquitectura basada en ResNet-50 que, mediante el aprendizaje de reglas compositivas (regla de los tercios, proporción áurea, simetría, ratio de aspecto, etc), sea capaz de predecir un vector de recorte de cuatro dimensiones (x, y, w, h).

- **OE4:** Desarrollo del módulo de colorimetría (*LUTNet*): Implementar una red basada en ResNet-18 que integre un vector de estadísticas globales (9D) para predecir curvas de ajuste tonal no lineales (17×3 canales), garantizando la fidelidad cromática y el atractivo visual.

- **OE5:** Integración del *pipeline* secuencial: Desarrollar el flujo de trabajo donde la salida del módulo *CropNet* condicione dinámicamente la entrada y el cálculo de estadísticas de *LUTNet*, asegurando una mejora cohesiva.

- **OE6:** Evaluación multivariante: Validar el sistema mediante métricas objetivas de calidad de imagen (NIQE, BRISQUE) y analizar los resultados, identificando las fortalezas, limitaciones y posibles líneas de mejora o extensión futura.

3.3. Metodología de trabajo

La metodología adoptada se basa en un enfoque de ingeniería de aprendizaje profundo secuencial, orientado al diseño de un *pipeline* de dos etapas: composición y colorimetría. Se estructura en cuatro fases: preparación de datos sintéticos, diseño de arquitecturas de regresión, entrenamiento especializado y evaluación multivariante.

3.3.1. Análisis y preparación del conjunto de datos

En esta primera etapa se lleva a cabo la recopilación, preprocesamiento y análisis exploratorio del *dataset*, con el fin de garantizar una base de datos adecuada para el entrenamiento y evaluación del modelo.

- ***Dataset***: se empleará Unsplash, una base de datos de fotografías de alta calidad con licencia libre. Este *dataset* resulta especialmente apropiado debido a la diversidad de escenas, estilos y composiciones, lo que permite capturar una amplia gama de condiciones visuales y estéticas. En la tabla 3.1 se aprecian los detalles técnicos del *dataset*.

- **Aprendizaje Auto-supervisado para LUTNet:** Se generan pares $\{I_{aug}, I_{ref}\}$ aplicando degradaciones sintéticas de color (brillo, contraste, *hue shift* y saturación). La red aprende a revertir estas perturbaciones para restaurar la estética profesional de la imagen de referencia. En la sección 4.3.1 se especifica la implementación técnica de esta estrategia.

- **Generación de pares para CropNet:** Se utiliza un modelo de difusión (*Stable Diffusion*) para realizar *outpainting*. Esto expande los márgenes de la imagen original, creando una composición deficiente. El sistema entrena para predecir el vector de recorte ($4D$) que recupere el encuadre profesional original. En la sección 4.3.2 se especifica la implementación técnica de esta generación de pares.

- **Preprocesamiento:** Normalización a resoluciones de 256×256 (CropNet) y 392×392 (LUTNet). Se extrae un vector de estadísticas globales ($9D$) para condicionar la mejora colorimétrica.

Característica	**Detalle**
Número de imágenes	25,000 (Versión Lite) / +5M (Versión Full)
Resolución	Alta resolución (variable, habitualmente > 3000px)
Formato de archivo	JPEG (Fotografía profesional)
Espacio de color	Principalmente sRGB
Contraste	Rango dinámico amplio (fotografía curada)
Metadatos	Datos EXIF (ISO, apertura, cámara), etiquetas y métricas
Licencia	Licencia Unsplash (Uso académico y comercial)

Tabla 3.1: Características principales del *dataset* Unsplash (Versión Lite)

Para el desarrollo de este proyecto, se ha seleccionado la versión *Lite* del conjunto de datos de Unsplash, una base de datos con un total de 25K imágenes de alta resolución

Figura 3.1: Ejemplo de imágenes en el *dataset* Unsplash.

curada por fotógrafos profesionales y entusiastas de todo el mundo. El uso de este *dataset* resulta idóneo para el entrenamiento de sistemas de mejora visual por tres motivos fundamentales:

1. **Validez estética y compositiva:** A diferencia de otros conjuntos de datos genéricos como ImageNet, las imágenes de Unsplash se caracterizan por una composición intencionada y el uso de reglas fotográficas (como la regla de los tercios o el uso de líneas de fuga). Esto permite que el modelo de composición utilice el *Ground Truth* original como una referencia de alta calidad estética sin necesidad de etiquetado manual adicional.

2. **Fidelidad cromática y rango dinámico:** Las capturas presentan un procesado de color profesional, con balances de blancos precisos y una gestión del contraste optimizada. Esta característica es esencial para el paradigma de aprendizaje auto-supervisado empleado, ya que garantiza que la red aprenda a mapear las imágenes degradadas sintéticamente hacia un estándar de calidad comercial y visualmente atractivo.

3. **Conjunto de metadatos:** Se cuenta con varios *dataframes* de metadatos que contienen información valiosa de las imágenes como número de descargas, número de visualizaciones, categorías y descripción. Estos metadatos ayudarán en el proceso de filtrado y limpieza del *dataset* para LUTNet y en la generación de los pares sintéticos para CropNet.

La diversidad semántica del *dataset*, que abarca desde paisajes y arquitectura hasta retratos, asegura que las redes neuronales desarrollen una capacidad de generalización robusta, evitando el sobreajuste a tipos de escena específicos y permitiendo una corrección coherente en diversos escenarios de iluminación. En la Figura 3.1 se aprecian 6 imágenes extraídas del *dataset* y usadas para el entrenamiento del sistema.

3.3.2. Diseño de la arquitectura del modelo

El sistema se diseña como un *pipeline* secuencial de regresión profunda, evitando arquitecturas generativas pesadas para optimizar la eficiencia y fidelidad. Para ello se toma como referencia los trabajos revisados en el estado del arte, especialmente en *CURL: Neural Curve Layers for Global Image Enhancement* (Moran y cols., 2020) y *NamedCurves: Learned Image Enhancement via Color Naming* (Serrano-Lozano y cols., 2024) (Ni y cols., 2020) respecto a la mejora técnica de la imagen y *Focusing on Your Subject: Deep Subject-Aware Image Composition Networks* (Ren, He, Girshick, y Sun, 2016) para la mejora compositiva, que se analizan previamente en 2.3.1 y 2.3.2 respectivamente.

- **Arquitectura CropNet (Composición):** Basada en una *ResNet-50* con transferencia de aprendizaje (*fine-tuning* del *layer 4*). Predice parámetros normalizados $[x, y, w, h]$ mediante una cabeza de regresión con *Dropout* al 50 %. Los parámetros $[x, y]$ indican los píxeles de comienzo en el eje horizontal y vertical de la imagen mientras que $[w, h]$ indican la anchura y altura del recorte. Es decir, se predice el punto de comienzo del recorte y su tamaño total.

- **Arquitectura LUTNet (Colorimetría):** Estructura bimodal que fusiona características semánticas de una *ResNet-18* con estadísticas de color ($9D$). Predice 51 puntos de control para generar curvas de ajuste tonal no lineales.
- **Funciones de pérdida:**
  - **Composición:** Combinación de error cuadrático medio (MSE) con pérdidas heurísticas: regla de los tercios, proporción áurea y simetría.
  - **Colorimetría:** Pérdida L1, suavizado de curvas (*Smooth Loss*), pérdida perceptual (VGG-16) y pérdida de crominancia.
- **Framework:** La implementación completa se realiza en **Python** utilizando **PyTorch** y **Kornia** para el procesamiento de imágenes acelerado por GPU.

Entrenamiento y validación

Durante esta fase se implementa un paradigma de aprendizaje supervisado apoyado en técnicas de generación de datos sintéticos. Mientras que el módulo de composición se entrena supervisando la regresión de coordenadas mediante pares de imágenes expandidas por difusión, el módulo de colorimetría emplea un enfoque auto-supervisado. En este último, la red aprende a realizar una edición profesional mediante la inversión de un *pipeline* de degradación fotométrica, utilizando las imágenes originales de alta calidad como su propia referencia de entrenamiento.

- **Configuración del entrenamiento:**
  - **Optimización:** Uso del algoritmo *Adam* con una tasa de aprendizaje inicial de 10^{-4} (CropNet) y 1×10^{-5} (LUTNet).
  - **Planificación de LR:** Implementación de un *Warmup Decay Scheduler* con decaimiento de coseno para estabilizar la convergencia inicial. Durante la fase de *warmup*, la tasa de aprendizaje aumenta gradualmente para estabilizar la actualización de los gradientes y evitar fluctuaciones drásticas debidas a la inicialización aleatoria. Posteriormente, el decaimiento de coseno reduce de forma suave el *learning rate* siguiendo una función cosenoidal, lo que facilita una convergencia más precisa hacia el mínimo global y mejora la capacidad de generalización del modelo sobre el *dataset*.

- **Regularización:** Aplicación de *Dropout* (0.5) y *Weight Decay* (10^{-4}) para mitigar el sobreajuste en el cabezal de regresión.
- ***Batch Size*:** Ajuste dinámico entre 8 y 32 muestras según la fase de entrenamiento y resolución de imagen.

- **Estrategias de validación:**
  - **División del *dataset*:** Partición aleatoria en subconjuntos de entrenamiento (80 %) y validación/prueba (20 %).
  - ***Early Stopping*:** Monitorización de la pérdida de validación con una paciencia de 5 a 10 épocas para detener el proceso en el punto de máxima generalización.
  - **Seguimiento:** Registro de métricas y curvas de pérdida mediante un *logger* y almacenamiento de puntos de control (*checkpoints*) para el mejor modelo obtenido.

Evaluación del modelo

La validación del sistema combina métricas técnicas de calidad de imagen con el análisis de la percepción estética humana, estructurándose en tres ejes:

- **Métricas objetivas sin referencia (IQA):** Dado que el objetivo es la mejora estética, se emplean métricas que evalúan la "naturalidad" y la ausencia de artefactos sin requerir una imagen original de comparación:
  - *Natural Image Quality Evaluator (NIQE):* Mide la desviación de la imagen respecto a un modelo estadístico de imágenes naturales utilizando una Distancia de Mahalanobis modificada:

    $$D(\nu_1, \nu_2, \Sigma_1, \Sigma_2) = \sqrt{((\nu_1 - \nu_2)^T \left(\frac{\Sigma_1 + \Sigma_2}{2}\right)^{-1} (\nu_1 - \nu_2))}$$

    donde ν_1, ν_2 son los vectores medios del modelo natural y de la imagen a evaluar y Σ_1, Σ_2 son las matrices de covarianza de ambos modelos.
  - *Blind/Referenceless Image Spatial Quality Evaluator (BRISQUE):* Evalúa la pérdida de calidad basada en la distorsión de las estadísticas de los coeficientes de luminancia. BRISQUE no se basa en una única fórmula cerrada, sino en el

ajuste de una Distribución Gaussiana Generalizada (GGD) sobre los coeficientes de los Coeficientes de Escena Normalizados (MSCN). La forma de la GGD es:

$$f(x;\alpha,\sigma^2) = \frac{\alpha}{2\beta\Gamma(1/\alpha)} \exp\left(-\left(\frac{|x|}{\beta}\right)^{\alpha}\right)$$

donde $\Gamma(\cdot)$ es la función gamma, $\beta = \sigma\sqrt{\frac{\Gamma(1/\alpha)}{\Gamma(3/\alpha)}}$. α controla la "forma" y σ^2 la varianza. Las características finales se extraen del ajuste de estos parámetros.

- **Evaluación subjetiva:**
  - *Mean Opinion Score (MOS):* Test ciego donde evaluadores humanos puntúan de 1 a 5 la calidad técnica y el atractivo visual de las imágenes antes y después del procesamiento. La métrica se calcula usando la media aritmética de las puntuaciones otorgadas por los sujetos:

$$MOS = \frac{\sum_{n=1}^{N} R_n}{N}$$

donde R_n es la puntuación (*rating*) otorgada por el sujeto n y N es el número total de evaluadores.

Documentación y análisis de resultados

Finalmente, se elaborará una evaluación crítica de los resultados obtenidos, discutiendo tanto las fortalezas del modelo como sus limitaciones. Se incluirá un análisis visual de ejemplos representativos y se propondrán líneas de trabajo futuro, como la extensión del modelo a vídeos o la integración de módulos de *feedback* humano.

4. Desarrollo específico de la contribución

4.1. Herramientas y *frameworks*

El desarrollo del sistema inteligente se llevó a cabo utilizando el lenguaje de programación Python (versión 3.12.3). Para la implementación de las redes neuronales profundas y la gestión del procesamiento de datos, se seleccionó un conjunto de librerías y *frameworks* de alto rendimiento detallados en las tablas 4.1 y 4.2.

Librería	**Versión**	**Función y justificación**
PyTorch	2.8.0	Framework principal. Utilizado por su grafo de cómputo dinámico y eficiencia en tareas de regresión bimodal.
Torchvision	0.23.0	Gestión de arquitecturas *backbone* (ResNet, VGG) y preprocesamiento de tensores.
TIMM	1.0.19	Integración de modelos de visión de vanguardia y experimentación con *encoders* optimizados.

Tabla 4.1: *Frameworks* de aprendizaje profundo

4.2. Entorno de cómputo

El entrenamiento y la validación de los modelos se realizaron en una estación de trabajo equipada con una GPU NVIDIA GeForce RTX 2070 (8GB VRAM), un procesador AMD Ryzen 3600 de 6 *cores* y 12 *threads* a una velocidad de 3.9GHz y un total de 32GB de memoria RAM. El uso de esta arquitectura, en combinación con librerías como Kornia y PyTorch, permitió paralelizar el cálculo de las funciones de pérdida complejas (perceptuales y cromáticas) y procesar lotes de imágenes de hasta 512×512 píxeles con tiempos de iteración eficientes.

Librería	**Versión**	**Función y justificación**
Kornia	0.8.1	**Fundamental.** Operadores de visión diferenciables en GPU. Permite realizar conversiones de color (RGB a HSV) sin latencia de transferencia CPU-GPU.
RawPy	0.25.1	Decodificación de archivos RAW para preservar el rango dinámico original durante el entrenamiento.
LPIPS	0.1.4	Cálculo de la distancia perceptual entre imágenes, alineada con el criterio visual humano.
OpenCV / Pillow	4.12.0 / 12.0.0	Operaciones auxiliares de bajo nivel y gestión de archivos de imagen.
NumPy / Pandas	2.2.2 / 2.3.2	Manipulación de estructuras matriciales y gestión de metadatos del *dataset*.
PyIQA	0.1.14.1	Cálculo de las métricas NIQE y BRISQUE en la evaluación de resultados.

Tabla 4.2: Librerías para procesamiento de imágenes y análisis de datos

4.3. Preprocesamiento de datos y generación de pares sintéticos

Debido a la ausencia de un *dataset* público que contenga pares de imágenes "antes y después" de una edición profesional, se ha diseñado un flujo de trabajo basado en el aprendizaje auto-supervisado. Bajo este paradigma, se asume que las imágenes de alta calidad (procedentes de Unsplash) representan el estado óptimo o *Ground Truth* (GT). A partir de estas, se generan versiones degradadas sintéticamente para que las redes neuronales aprendan a inferir la función inversa de restauración y mejora.

4.3.1. Módulo de colorimetría (LUTNet)

El entrenamiento de este módulo se fundamenta en un paradigma auto-supervisado, aprovechando la capacidad de la red para inferir la función inversa de degradación. Dado que no siempre es factible contar con grandes volúmenes de pares de imágenes reales "malas" y "buenas" perfectamente alineadas, se diseñó e implementó un *pipeline* de au-

mento de datos (*data augmentation*) robusto. Este sistema genera dinámicamente pares de entrenamiento conformados por una imagen degradada sintéticamente y su contraparte de referencia original de alta calidad (img_ref), simulando así una amplia casuística de errores fotográficos que el modelo deberá aprender a subsanar.

El proceso comienza abordando las imperfecciones básicas relacionadas con la exposición y la nitidez, simulando las limitaciones físicas de sensores modestos o errores en la toma. Para ello, se aplican transformaciones en el dominio perceptivo mediante la librería Pillow 4.2. Con una probabilidad de $p < 0{,}5$, la imagen se somete a variaciones multiplicativas uniformes de brillo y contraste dentro del rango $[0{,}4, 1{,}0]$, emulando fotografías subexpuestas o con rangos dinámicos pobres. De igual manera, se altera la saturación del color bajo los mismos parámetros para replicar la pérdida de viveza cromática. Adicionalmente, para dotar al modelo de resistencia frente a problemas de enfoque o movimiento de la cámara, se aplica un filtro de desenfoque Gaussiano con un radio aleatorio en una proporción menor de los casos ($p < 0{,}3$).

En una segunda etapa, el sistema se enfoca en las dominantes de color y los errores de balance de blancos, que constituyen uno de los desafíos más comunes en la fotografía *amateur*. Para replicar estas condiciones, se ejecuta una transformación de *RGB Shifting* con una alta frecuencia de aparición ($p < 0{,}7$). Esta operación aplica un transformación lineal independiente a cada canal de color, consiguiendo así mover el histograma de cada canal en los siguientes rangos ($R, B \in [0{,}6, 1{,}4]$ y $G \in [0{,}7, 1{,}3]$). Es decir, para los canales rojo y azul se moverá el histograma hasta un 40 % a la izquierda o la derecha y en el caso del canal verde se moverá hasta un 30 %. Esta independencia entre canales es crucial, ya que permite simular tintes de color complejos (como el exceso de verdosos o azulados típicos de iluminaciones artificiales) que obligan a la red a entender la relación entre canales para recuperar la neutralidad del color.

Finalmente, se introduce una de las degradaciones más críticas para el aprendizaje de la coherencia cromática: la desviación de tono o *Hue Shift*. Aprovechando la aceleración por GPU de la librería Kornia, las imágenes se convierten al espacio de color HSV para desplazar el componente de tono (Hue) de forma aditiva con un valor aleatorio de ± 20 grados con una probabilidad $p < 0{,}7$. La inclusión de esta técnica responde a una necesidad específica del aprendizaje profundo en edición de imagen: los errores de tono implican una rotación en el círculo cromático que no puede corregirse eficientemente mediante simples curvas RGB o minimizando una pérdida $L1$ estándar. Al forzar al modelo a revertir estos

cambios de tono, se asegura que la red no solo memorice ajustes de brillo, sino que desarrolle una comprensión profunda de la armonía del color.

Como paso final dentro del *pipeline* del *dataset*, se calcula un vector de estadísticas de color a partir de la imagen degradada. Este vector de 9 dimensiones se utiliza como entrada complementaria para el codificador. Esto permite que la red condicione la curva de corrección no solo en el contenido visual, sino también en un resumen cuantitativo explícito de los problemas colorimétricos actuales de la imagen. La integración de estas técnicas de *data augmentation* permite que el modelo aprenda una función de mapeo robusta $\mathcal{F}_{\text{color}} : (\text{I}_{\text{aug}}, \mathbf{S}) \rightarrow \text{I}_{\text{ref}}$, donde $\mathbf{S}$ es el vector de estadísticas, mejorando significativamente la capacidad de generalización y la robustez del módulo de colorimetría.

4.3.2. Módulo de composición

Para el entrenamiento supervisado del módulo de composición, se creó un conjunto de datos sintético basado en la hipótesis de que las imágenes publicadas originalmente en plataformas como Unsplash son composiciones estéticamente válidas (*Ground Truth*). El desafío es transformar estas imágenes de *Ground Truth* (GT) en imágenes de entrada sin recortar (Input X) con márgenes ambiguos, a partir de las cuales la red debe aprender a "redescubrir" la composición original.

El proceso de creación del conjunto de datos utiliza una técnica de generación de imágenes por difusión condicional *Stable Diffusion Inpainting Pipeline* (Rombach, Blattmann, Lorenz, Esser, y Ommer, 2022) para expandir los límites de la imagen original, como se ilustra en la Figura 4.1. El flujo comienza con la selección del *Ground Truth*, que en este caso consta de 1.250 imágenes de alta calidad. A continuación, la imagen entra en el módulo de inferencia y se inicia la preparación adaptativa del lienzo. Para mitigar cualquier sesgo posicional fijo, el algoritmo introduce una variabilidad crítica al crear un área de expansión (*padding*) de 256 píxeles, decidiendo aleatoriamente expandir la imagen en uno o dos de sus cuatro lados (superior, inferior, izquierda, derecha). Seguidamente, se genera la máscara necesaria para el modelo, suavizada mediante un desenfoque Gaussiano (radio = 10) para asegurar la coherencia en la transición entre el contenido original y el contenido generado.

Tras generar una imagen auxiliar como resultado de la preparación, la inferencia de difusión (*Outpainting*) se realiza utilizando el modelo *Stable Diffusion 1.5 Inpainting* (RunwayML, 2022) rellenando las áreas enmascaradas. Para garantizar la coherencia se-

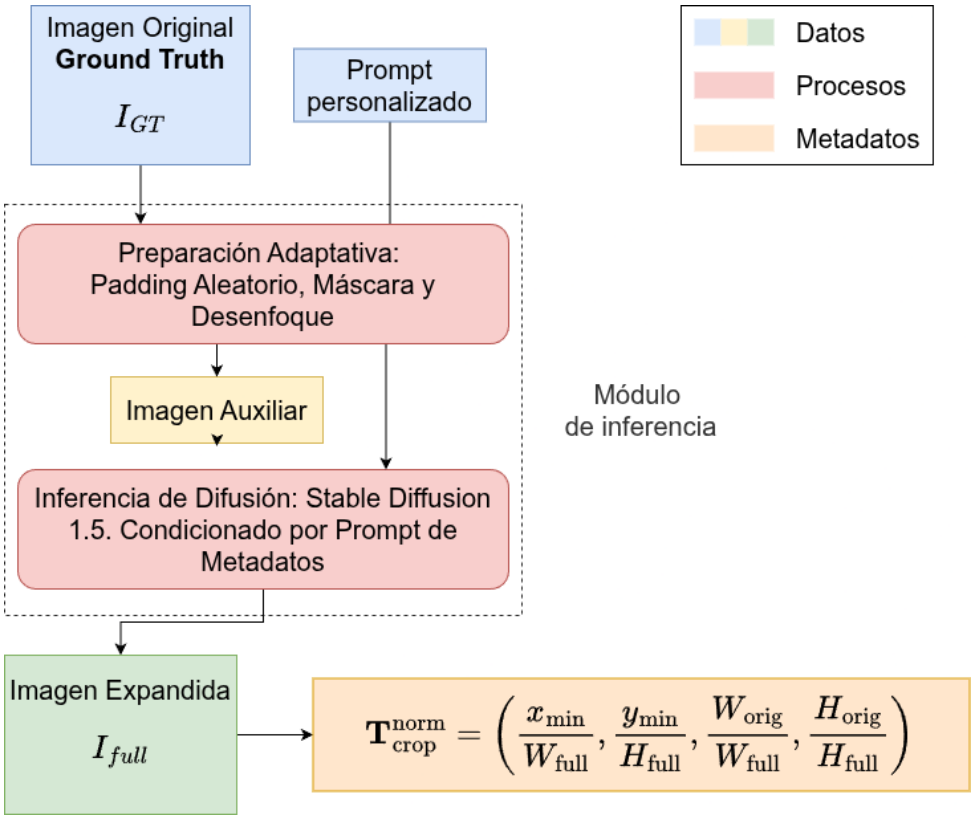

Figura 4.1: Esquema de generación del conjunto de datos de entrenamiento para el módulo de composición.

mántica del contenido generado (es decir, que el modelo continúe un cielo con nubes y no con asfalto), el proceso se condiciona mediante un *prompt* textual derivado de la descripción que acompaña a la imagen original en los metadatos del *dataset* de Unsplash como se vió previamente en 3.3.1. Aunque la inferencia se realiza eficientemente a un tamaño de 512×512 (el óptimo para el modelo SD 1.5), la imagen resultante se reescala al tamaño completo expandido ($\mathbf{I}_{\text{full}}$) para su posterior uso.

Finalmente, se procede a la generación de etiquetas de recorte (Y). La imagen expandida ($\mathbf{I}_{\text{full}}$) se convierte en la entrada X para el entrenamiento de la red. La etiqueta *Ground Truth* (Y) se compone de los parámetros normalizados de las coordenadas del recorte original (I_{GT}) dentro de la imagen expandida. Estos cuatro parámetros definen la ubicación espacial y las dimensiones del recorte ideal:

$$\mathbf{T}_{\text{crop}}^{\text{norm}} = \left(\frac{x_{\text{min}}}{W_{\text{full}}}, \frac{y_{\text{min}}}{H_{\text{full}}}, \frac{W_{\text{orig}}}{W_{\text{full}}}, \frac{H_{\text{orig}}}{H_{\text{full}}} \right)$$

donde $(W_{\text{full}}, H_{\text{full}})$ son las dimensiones de $\mathbf{I}_{\text{full}}$ y $(x_{\text{min}}, y_{\text{min}}, W_{\text{orig}}, H_{\text{orig}})$ describen la región de la imagen original. Este proceso concluye con la obtención de un conjunto de

datos de 1.250 imágenes completamente etiquetadas de forma automática, listas para el entrenamiento supervisado del modelo de composición.

4.4. Arquitectura de la solución

El sistema propuesto integra dos redes neuronales profundas en un flujo de trabajo modular: un módulo de regresión bimodal para la corrección cromática y un regresor geométrico para la optimización compositiva. Este diseño modular permite desacoplar la interpretación semántica del color de la estructura espacial de la imagen, facilitando un control preciso sobre cada dimensión estética.

4.4.1. Módulo de colorimetría por curvas

Basado en la arquitectura de curvas de color aprendidas que presentan los autores en el trabajos (Moran y cols., 2020) y (Serrano-Lozano y cols., 2024), este módulo no genera píxeles, sino que infiere funciones de mapeo tonal no lineales. El objetivo es predecir un conjunto de curvas paramétricas que transformen la imagen de entrada en función de su contexto visual y sus propiedades estadísticas.

Estructura Bimodal y Componentes

El módulo sigue un esquema *encoder-predictor* que opera bajo una arquitectura bimodal, como se detalla en la Figura 4.2. Los dos flujos de entrada (visual y estadístico) se integran para predecir las transformaciones de color necesarias.

El Codificador de Contenido (*Encoder*) se implementa con una red ResNet-18 (He, Zhang, Ren, y Sun, 2015) preentrenada en ImageNet. Esta elección aprovecha su capacidad para extraer características de alto nivel relevantes para la interpretación de la escena. La capa final (*Fully Connected*) de la ResNet-18 se sustituye por una capa de identidad para obtener un vector de características visuales de 512 dimensiones.

Este vector de contenido se complementa con un vector de estadísticas de color (9D), calculado explícitamente a partir de la imagen para introducir información directa sobre su estado colorimétrico (e.g., media, desviación estándar de los canales RGB). Para el cálculo de este vector se usa la redd VGG16 (Simonyan y Zisserman, 2015).

Las características visuales y las estadísticas de color se concatenan para formar un vector de entrada de 521 dimensiones. Este vector alimenta el Cabezal Predictor (Final

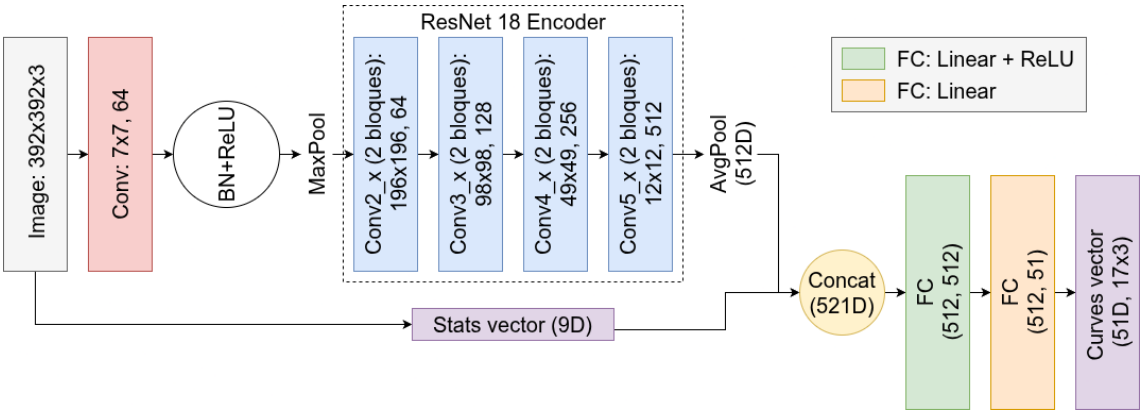

Figura 4.2: Arquitectura del módulo de colorimetría. Para el codificador se usa de base una ResNet-18 que extrae características semánticas de la imagen en la que se sustituye la última capa FC por una capa identidad. Adicionalmente, se extrae un vector de estadísticas globales de color mediante la red VGG16. El cabezal final de regresión toma estas entradas y predice un vector de desplazamientos (Δ) sobre curvas de identidad para ajustes tonales en los canales RGB y brillo.

Fuente: propia

FC), una capa lineal que predice $3 \times 17 = 51$ valores, correspondientes a los desplazamientos (Δ) necesarios para las curvas de ajuste (una curva de brillo y tres curvas RGB, cada una con 17 puntos de control).

Componente	**Función Principal**	**Dimensión de Salida**
ResNet-18 Encoder	Extracción de características visuales	512
Vector de Estadísticas VGG16	Entrada de estado colorimétrico explícito	9
Capa de Concatenación	Fusión bimodal de características	521
Cabezal Predictor (FC)	Predicción de puntos de control ($\boldsymbol{\Delta}$)	51

Tabla 4.3: Resumen de componentes y dimensiones del módulo de colorimetría

La optimización del modelo se basa en una función de pérdida combinada ($\mathcal{L}_{\text{total}}$) que integra múltiples componentes para guiar al modelo a producir resultados fotorrealistas, con coherencia cromática y estructural.

$$L_{\text{total}} = \lambda_{L_1} L_1 + \lambda_{\text{S}} L_{\text{S}} + \lambda_{\text{ID}} L_{\text{ID}} + \lambda_P L_P + \lambda_{\text{C}} L_{\text{C}} + \lambda_G L_G + \lambda_{TM} L_{TM} + \lambda_{CP} L_{CP}$$

Desglosando esta función de pérdida combinada tenemos las siguientes funciones de pérdida en la Tabla 4.4.

Símbolo	**Componente de Pérdida**	**Formulación**	**Descripción y Justificación**
L_1	Pérdida de Pixeles	$\frac{1}{n}\sum_{i=1}^{n}\lvert y_i - \hat{y}_i\rvert$	Mide la diferencia absoluta media entre la imagen generada (*fake*) y la referencia (img_ref). Es la base para la reconstrucción de la imagen.
L_{S}	Suavidad de Curva	$\sum_{i=2}^{n-1}\lVert p_{i+1} - 2p_i + p_{i-1}\rVert^2$	Penaliza las oscilaciones abruptas en los puntos de las curvas generadas, asegurando una transformación local visualmente suave.
L_{ID}	Pérdida de Identidad	$\mathbb{E}_{x\sim P_{data}}[\lVert G(x) - x\rVert_1]$	Mide la desviación de las curvas generadas respecto a las curvas de identidad, incentivando transformaciones entrantes y controladas.
L_{P}	Pérdida Perceptual (VGG)	$\sum_{j\in J}\frac{1}{C_j H_j W_j}\lVert\phi_j(y) - \phi_j(\hat{y})\rVert_2^2$	Mide la distancia entre las características extraídas por una red VGG-16 preentrenada, tanto para la imagen generada como para imágenes que son perceptualmente similares a la referencia.
L_{C}	Pérdida HSV (*Hue, Saturation* y *Value*/Intensidad)	$\lambda_h\lVert y_h - \hat{y}_h\rVert_1 + \lambda_s\lVert y_s - \hat{y}_s\rVert_1 + \lambda_v\lVert y_v - \hat{y}_v\rVert_1$	Incluye términos para *Hue, Saturation* y *Value* (luminosidad) en el espacio HSV, enfocándose en la precisión del color y el contraste perceptual.
L_g	Pérdida de Gradiente	$\sum_{i,j}(\lVert\nabla_x y_{i,j} - \nabla_x\hat{y}_{i,j}\rVert_1 + \lVert\nabla_y y_{i,j} - \nabla_y\hat{y}_{i,j}\rVert_1)$	Penaliza las diferencias en los gradientes espaciales de las imágenes para preservar los detalles finos y los bordes.
L_{TM}	Pérdida de Mapeo Tonal	$\sum_{i,j}\lVert\mathcal{T}(y_{i,j}) - \mathcal{T}(\hat{y}_{i,j})\rVert_1$	Se enfoca en la corrección de los tonos y sombras (*shadows*) e iluminaciones (*highlights*), mejorando el rango dinámico.
L_{CP}	Pérdida Perceptual Cromática	$\sum_{j\in J}\lVert\phi_j(y_{uv}) - \phi_j(\hat{y}_{uv})\rVert_2^2$	Pérdida perceptual aplicada específicamente a la crominancia para evitar artefactos y shifts de color no deseados.

Tabla 4.4: Desglose de las funciones de pérdida individuales de la red de mejora de colorimetría basada en curvas

A diferencia del trabajo de (Serrano-Lozano y cols., 2024) que usa un enfoque semántico mediante *color naming*, este trabajo usa el vector de color como un crítico de color perceptual. Este vector asegura que la optimización de las curvas no solo busque la coincidencia matemática, sino la plausibilidad visual de los colores.

Asimismo, esta arquitectura presenta diferencias fundamentales respecto a CURL (Moran y cols., 2020). Mientras que CURL propone una aplicación secuencial de curvas en múltiples espacios de color (RGB, HSV y Lab) mediante una red de codificador-decodificador compleja, este diseño simplifica la ejecución aplicando las transformaciones exclusivamente en el espacio RGB optimizado mediante desplazamientos (Δ). No obstante, la robustez multiespacial de CURL se integra aquí de forma implícita a través de las funciones de pérdida, utilizando el espacio Lab (vía VGG16) y HSV para supervisar la crominancia y el mapeo de tonos (*tone mapping*), garantizando así una suavidad en las transiciones y una protección contra artefactos que supera a las curvas lineales a trozos de CURL.

Generación y aplicación de curvas

Los valores predichos por el cabezal (Predicción) se interpretan como desviaciones o desplazamientos ($\mathbf{\Delta}$) respecto a un conjunto de curvas identidad predefinidas. Para asegurar que las transformaciones sean suaves y realistas, la función de activación tanh se aplica a la predicción y se escala por un factor de 0,4, limitando así el rango del ajuste:

$$\mathbf{\Delta} = 0{,}4 \cdot \tanh(\text{Predicción})$$

Finalmente, las curvas de ajuste ($\mathbf{C}$) se obtienen sumando las desviaciones a las curvas identidad ($\mathbf{I}$) y se restringen al rango $[0, 1]$ mediante la función clamp, evitando valores no físicos:

$$\mathbf{C} = \text{clamp}(\mathbf{I} + \mathbf{\Delta}, 0, 1)$$

El proceso concluye aplicando estas curvas $\mathbf{C}$ a los canales RGB de la imagen de entrada, resultando en la imagen de salida corregida.

Esquema de fases de entrenamiento

El entrenamiento se divide en dos fases secuenciales, utilizando una estrategia de calentamiento (*warmup*) y decaimiento del *learning Rate* (LambdaLR con decaimiento coseno) para una convergencia estable.

La primera fase se centra en un aprendizaje rápido de base que usa una muestra pequeña de 250 imágenes de 512 por 512 píxeles de tamaño. Se usa un *learning rate* alto con un valor de 5×10^{-3}. Los pesos de la pérdida L_1 y L_g también tienen un valor alto con la finalidad de asegurar que la red mantiene una salida estable y que no difiere mucho de la imagen original.

El entrenamiento se limita a 50 épocas con un total de 10 épocas de *warmup*. Al trabajar con imágenes de 512 por 512 píxeles se usa un *batch size* de 4. Para esta primera fase los pesos utilizados para las funciones de pérdida los encontramos en la Tabla 4.5.

Pérdida	**Peso**	**Valor**
Pérdida de píxeles	λ_{L_1}	8×10^{-1}
Suavidad de curva	λ_{S}	15×10^{-1}
Pérdida de identidad	λ_{ID}	3×10^{-2}
Pérdida perceptual (VGG)	λ_P	0,0
Pérdida HSV	λ_C	2×10^{-2}
Pérdida de gradiente	λ_G	1×10^{-1}
Pérdida de mapeo tonal	λ_{TM}	5×10^{-3}
Pérdida perceptual cromática	λ_{CP}	0,0

Tabla 4.5: Pesos de las funciones de pérdida del módulo de colorimetría en la fase 1.

En la segunda fase se busca una generalización robusta usando un mayor conjunto de imágenes que permitan obtener características más variadas. Para ello se utiliza un subconjunto de 5000 imágenes del conjunto de datos de Unsplash. Para filtrar este subconjunto se usan los metadatos vistos en 3.3.1 y se eligen las primeras 5000 imágenes con una mayor estadística de total de descargas ordenadas de forma descendente. De esta forma se consigue contar con un menor conjunto de datos que permitirá acelerar el procesamiento de entrenamiento y asegurar que las imágenes que se usan para entrenar la red son relevantes y poseen las características idóneas para el propósito de la red que es lograr mejorar una imagen logrando un resultado similar al de un fotógrafo profesional. En este caso, el tamaño de las imágenes se reduce a 392 por 392 píxeles y se baja el *learning rate* a un valor de 1×10^{-5}. Se usa un total de 50 épocas en esta segunda fase y se aumenta el *batch size* a un valor de 8.

En esta fase se comienza a tener en cuenta el posible *overfitting* del modelo, por lo que se divide el conjunto de datos en entrenamiento y validación con unos porcentajes de 80 %

y 20 % respectivamente. Además se incluye una regla de *Early Stopping* cuando la pérdida total en el conjunto de validación no muestre mejoras durante 5 épocas.

Al haber entrenado ya un modelo estable en la primera fase, en esta se modifican los pesos para permitir una mayor generalización de los datos y motivar el aprendizaje en la generación de curvas. En la Tabla 4.6 se aprecian los nuevos pesos usados para el entrenamiento en esta fase.

Pérdida	**Peso**	**Valor**
Pérdida de píxeles	λ_{L_1}	6×10^{-1}
Suavidad de curva	λ_{S}	15×10^{-1}
Pérdida de identidad	λ_{ID}	1×10^{-1}
Pérdida perceptual (VGG)	λ_P	6×10^{-2}
Pérdida HSV	λ_C	5×10^{-3}
Pérdida de gradiente	λ_G	1×10^{-1}
Pérdida de mapeo tonal	λ_{TM}	5×10^{-3}
Pérdida perceptual cromática	λ_{CP}	5×10^{-2}

Tabla 4.6: Pesos de las funciones de pérdida del módulo de colorimetría en la fase 2.

4.4.2. Módulo de composición

El segundo componente de la contribución se enfoca en optimizar la composición de la fotografía. Para ello, se desarrolla este sistema siguiendo el enfoque de GenCrop-Net (Hong, Yuan, Gharbi, Fisher, y Fatahalian, 2024). Este módulo opera como un regresor supervisado que predice los cuatro parámetros normalizados que definen el recorte óptimo de una imagen: $\mathbf{P}_{\text{crop}} = (x_{\min}, y_{\min}, x_{\max}, y_{\max})$, donde los valores están normalizados al rango $[0, 1]$.

Estructura y componentes de la red

La arquitectura se basa en un esquema *encoder-regressor*, diseñado para extraer características compositivas complejas y mapearlas a una salida de regresión controlada. En la Figura 4.3 se aprecia la arquitectura del modelo.

Se cuenta con un codificador (*backbone*) que utiliza la red ResNet-50 preentrenada en ImageNet (versión IMAGENET1K_V2) como extractor de características. Se elige esta red

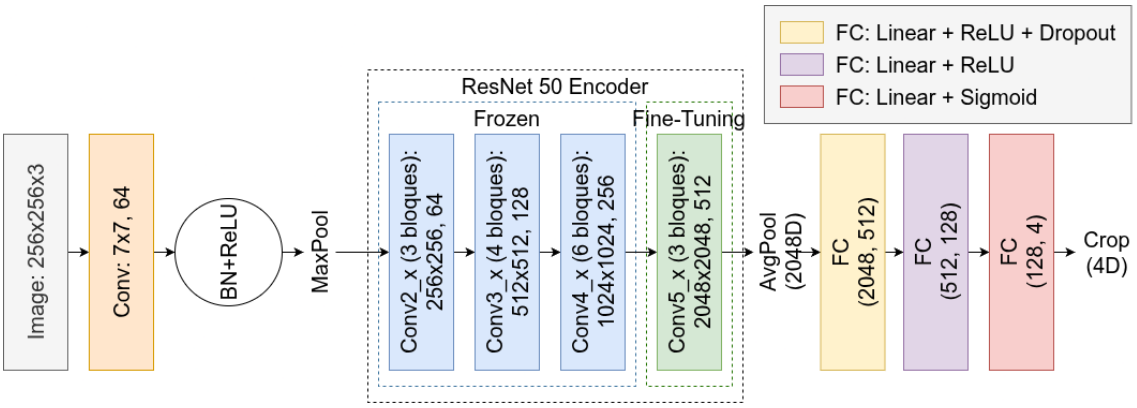

Figura 4.3: Arquitectura del módulo de composición. Para el codificador se usa de base una ResNet-50 con los pesos congelados en los primeros bloques. Esta red permite extraer características muy complejas de la imagen para finalmente predecir un vector de regresión con los parámetros que permiten el recorte ideal.
Fuente: propia

por su profundidad y rendimiento comprobado en tareas de reconocimiento visual. Inicialmente, los parámetros del *backbone* se congelan para aprovechar los pesos preentrenados. No obstante, para permitir un buen ajuste (fine-tuning) específico para la composición, se descongelan los parámetros del último bloque convolucional durante el entrenamiento.

En la parte del regresor se cuenta con un cabezal de regresión compuesto por capas densas que toma como entrada un vector de características de 2048 dimensiones extraído por la ResNet-50. Este cabezal incluye una capa de Dropout con una tasa elevada del 50 %. Este aumento en la regularización se implementa para combatir el sobreajuste al conjunto de datos de etiquetas de recorte, que suelen ser más subjetivas y ruidosas que las etiquetas de clasificación de color. La capa de salida final utiliza la función de activación sigmoide, asegurando que los cuatro parámetros de recorte predichos se mantengan estrictamente dentro del rango $[0, 1]$, tal como se requiere para las coordenadas normalizadas. A diferencia del trabajo presentado por (Hong y cols., 2024), que usa una arquitectura basada en puntos de anclaje y que requiere de una máscara binaria de entrada con el sujeto, este módulo opera directamente con una imagen y realiza un recorte inteligente sin necesidad de especificar el sujeto gracias al conjunto de pérdidas usadas durante el entrenamiento.

El desarrollo de la función de pérdida incorpora la pérdida MSE (Mean Squared Error) que penaliza los errores grandes sobre los pequeños, y una serie de pérdidas de regularización que codifican reglas composicionales fundamentales. La pérdida total de entrena-

miento (L_{comp}) se define como:

$$L_{\text{comp}} = L_{\text{MSE}} + \sum_i \lambda_i L^i_{\text{comp}}$$

donde L_{MSE} es la pérdida de error cuadrático medio estándar respecto a los parámetros de recorte de referencia, y L^i_{comp} son las pérdidas composicionales ponderadas por λ_i que se pueden ver con más detalle en la Tabla 4.7.

Símbolo	Componente de Pérdida	Formulación	Descripción y Justificación
L_{MSE}	Pérdida de Pixeles	$\lVert I_{fake} - I_{ref} \rVert_1$	Mide la diferencia absoluta media entre la imagen generada (*fake*) y la referencia (img_ref). Es la base para la reconstrucción de la imagen.
L_{ROT}	Regla de los tercios	$\sum_{i,j} \lVert P_{focal} - T_{i,j} \rVert^2$	Penaliza los recortes que no alinean el centro o puntos focales con los tercios horizontales y verticales ($T_{i,j}$).
L_{GR}	Proporción áurea	$\lVert \frac{a+b}{a} - \varphi \rVert^2$	Fomenta la adherencia a la proporción áurea ($\varphi \approx 1{,}618$), un principio clave en la estética fotográfica.
L_{AR}	Ratio de aspecto	$\lVert \frac{w}{h} - R_{target} \rVert^2$	Penaliza desviaciones del ratio de aspecto deseado o de la referencia, manteniendo la coherencia estructural.
L_{S}	Simetría	$\lVert I(x,y) - I(-x,y) \rVert_1$	Incentiva la simetría o la alineación del sujeto en composiciones donde aplica.
L_{C}	Pérdida de centro	$\lVert C_{crop} - C_{img} \rVert^2$	Aplica una penalización cuando el centro del recorte está excesivamente desviado del centro ideal.
L_{M}	Pérdida de margen	$\max(0, m_{min} - d_{edge})$	Fomenta un margen adecuado entre el borde del recorte y el sujeto, evitando recortes demasiado ajustados.

Tabla 4.7: Funciones de pérdida de la red de mejora de composición.

Esquema de fases de entrenamiento

El entrenamiento del módulo de composición se lleva a cabo en una única fase supervisada (a diferencia del entrenamiento progresivo del módulo de colorimetría), enfocándose en la optimización de la función de pérdida compuesta y el *fine-tuning* del *backbone ResNet-50*. El objetivo principal es lograr la convergencia de los parámetros de regresión hacia el espacio definido por las reglas de composición codificadas en las pérdidas de la Tabla 4.7.

Se inicializa la arquitectura GenCrop-Net con un *backbone ResNet-50* preentrenado con pesos ImageNet. Inicialmente, solo los parámetros del cabezal de regresión son entrenables. Esto permite un ajuste más rápido en las capas densas en la tarea de regresión. Progresivamente se descongelan los parámetros del último bloque convolucional del *backbone* en la capa 4. Esto facilita que el modelo adapte las características de alto nivel extraídas por la red específicamente a la tarea de predicción de composición estética, más que a la clasificación genérica de objetos.

Se utiliza el optimizador Adam para gestionar la actualización de los pesos. Para asegurar la estabilidad, se aplican tasas de aprendizaje diferenciadas (*differential learning rates* (Ivanov, 2017)). La tasa de aprendizaje (lr) es mayor para el Cabezal de Regresión (1×10^{-4}), que necesita aprender la nueva tarea rápidamente. La tasa de aprendizaje para el bloque layer4 del *backbone* es significativamente menor (lr/10), lo que permite el *fine-tuning* sutil sin corromper el conocimiento preentrenado.

En cuanto a la regularización se utiliza *Weight Decay* (1×10^{-4}) y una tasa de *Dropout* aumentada (0.5) en el cabezal de regresión para evitar el sobreajuste al conjunto de datos sintético debido a que se cuenta con una baja cantidad de imágenes.

De igual forma que en el caso del módulo de colorimetría, se usa validación cruzada y un criterio de parada para evitar el sobreajuste. Para ello, el conjunto de datos se divide en un conjunto de entrenamiento y un conjunto de validación con un porcentaje de 90 % y 10 % respectivamente. En este caso, al contar con un menor número de imágenes en el conjunto de entrenamiento se opta por usar tan sólo el 10 % de los datos para la validación. El entrenamiento se monitorea con la pérdida total en el conjunto de validación y se detiene si la pérdida de validación no mejora durante 10 épocas consecutivas, garantizando que se seleccione el modelo con la mejor capacidad de generalización. Al contrario que en el módulo de colorimetría, en este modelo los pesos se mantienen estables durante todo el entrenamiento. En la Tabla 4.8 se aprecian los pesos utilizados para las funciones de

pérdida de la Tabla 4.7.

Pérdida (Regla Composicional)	**Peso (λ_i)**	**Valor**
Regla de los tercios (L_{ROT})	λ_{ROT}	0.9
Proporción áurea (L_{GR})	λ_{GR}	0.8
Ratio de aspecto (L_{AR})	λ_{AR}	0.9
Simetría (L_{A})	λ_{S}	0.6
Pérdida de centro (L_{C})	λ_{C}	0.2
Pérdida de margen (L_{M})	λ_{M}	0.3

Tabla 4.8: Pesos de las funciones de pérdida del módulo de composición.

4.5. Análisis de Resultados

4.5.1. Métricas de entrenamiento del módulo de colorimetría

Como se comenta en la Sección 4.4.1, el entrenamiento del módulo de colorimetría se dividió en dos fases principales, reflejando un enfoque de optimización por etapas. La fase inicial, al contar con un menor número de muestras en el conjunto de entrenamiento y un *learning rate* alto, permite una convergencia rápida del modelo. Se observa una rápida disminución de la pérdida de entrenamiento (T-Loss), pasando de $\mathcal{L}_{\text{Epoch 1}} = 0{,}2160$ a $\mathcal{L}_{\text{Epoch 50}} = 0{,}0911$ en un tiempo de 1036,65 segundos ($\approx$ 17 minutos). Estos resultados dan un tiempo promedio de $\approx$ 20 segundos por época. En la Figura 4.4 se aprecia la evolución de la pérdida en la primera fase.

En la segunda etapa se implementó una estrategia de *fine-tuning* con un **tamaño de imagen reducido** (Size = 392) y una tasa de aprendizaje más baja (η = 1e-05). El cambio más significativo fue la introducción de una **función de pérdida compuesta** más sofisticada, diseñada para mejorar la calidad perceptual y la estructura del color. Al contar con un mayor número de muestras en el conjunto de datos e implementar mecanismos de *Early Stopping* teniendo en cuenta la pérdida en el conjunto de validación se consigue que la red aprenda a trabajar con imágenes nuevas y evitar el *overfitting*. En esta etapa, al contar con una pérdida más compleja y un mayor número de datos, la pérdida no presenta una convergencia tan grande como la de la fase previa, pasando de $\mathcal{L}_{\text{Epoch 51}} = 0{,}1908$ a $\mathcal{L}_{\text{Epoch 115}} = 0{,}1236$ en un tiempo de 17435,18 segundos ($\approx$ 4,85 horas). De esta forma se

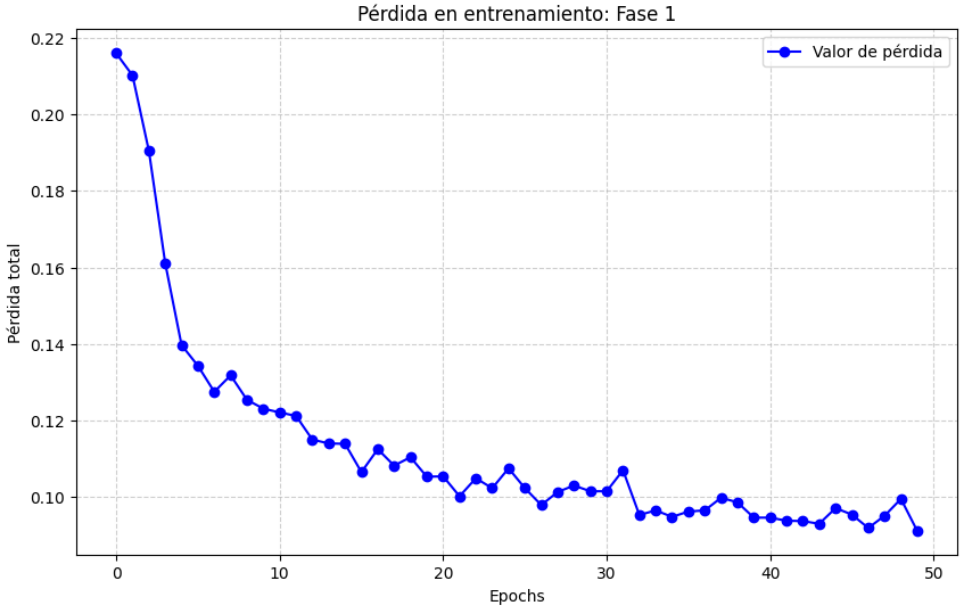

Figura 4.4: Evolución de la pérdida en la fase 1 de entrenamiento del módulo de colorimetría.

obtiene un tiempo medio de entrenamiento de ≈ 272 segundos por época. En la Figura 4.5 se aprecia la evolución de la pérdida en el conjunto de validación en la segunda fase. El entrenamiento en esta segunda fase termina gracias al mecanismo de *Early Stopping* al no encontrar una mejora en la pérdida para el conjunto de validación durante 5 iteraciones seguidas.

4.5.2. Métricas de entrenamiento del módulo de composición

El entrenamiento del módulo de composición fue dirigido por una función de pérdida compuesta multifactorial ($\mathcal{L}_{\text{comp}}$), diseñada para simular el juicio estético humano mediante la penalización de desviaciones respecto a múltiples reglas de composición.

El entrenamiento se ejecutó durante 63 épocas con una tasa de aprendizaje constante de $\eta = 0{,}0001$. La pérdida total inicial ($\mathcal{L}_{\text{Epoch 1}} = 0{,}253257$) se redujo drásticamente en las primeras épocas, alcanzando un valor estable y bajo ($\mathcal{L}_{\text{Epoch 10}} = 0{,}039009$) y terminando en $\mathcal{L}_{\text{Total}} = \mathbf{0{,}034967}$ en la época 63 en un total de 4770 segundos ($\approx$ 1,3 horas). Obteniendo de esta forma un promedio de ≈ 64 segundos por época.

El entrenamiento se concluyó anticipadamente en la época 63 por la activación de la estrategia de *Early Stopping*, lo cual garantiza un modelo robusto que ha convergido a un

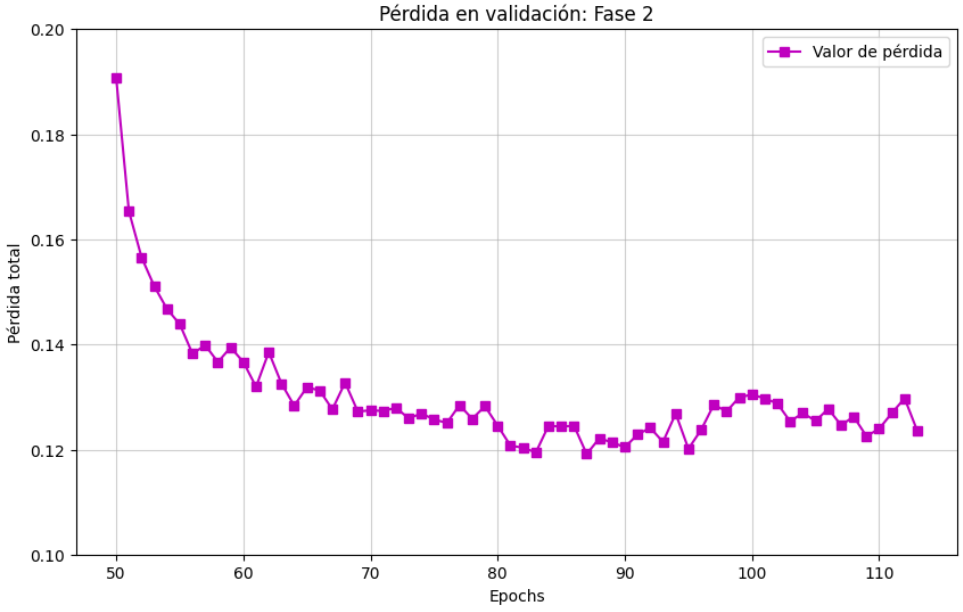

Figura 4.5: Evolución de la pérdida en la fase 2 de entrenamiento del módulo de colorimetría.

mínimo estable sin sobreajustar a los datos de entrenamiento. En la Figura 4.6 se aprecia la evolución de la convergencia de la red.

4.5.3. Métricas de inferencia y calidad perceptual

La calidad de las imágenes resultantes (tras aplicar la corrección de color y el recorte) fue evaluada utilizando métricas ciegas a la referencia *(No-Reference Image Quality Assessment - NR-IQA)*, que son ideales para evaluar la calidad perceptual y el realismo sin necesidad de una imagen original. Para la evaluación se utilizaron las métricas BRISQUE y NIQE, cuyas puntuaciones indican la calidad global de la imagen. En ambas, una puntuación menor indica una mejor calidad percibida.

La métrica NIQE (*Naturalness Image Quality Evaluator* mide la distancia entre la distribución de características de la imagen de prueba y un modelo de características obtenido de imágenes naturales prístinas. Esta métrica opera bajo el supuesto de que las imágenes naturales, libres de distorsiones, exhiben patrones estadísticos altamente predecibles y consistentes en sus coeficientes de intensidad, un principio conocido como el Modelo de Estadísticas de Campo de Coeficientes de Intensidad (CSS). NIQE mide si la imagen se ve como una foto bien tomada, con colores realistas y texturas naturales lo que permite

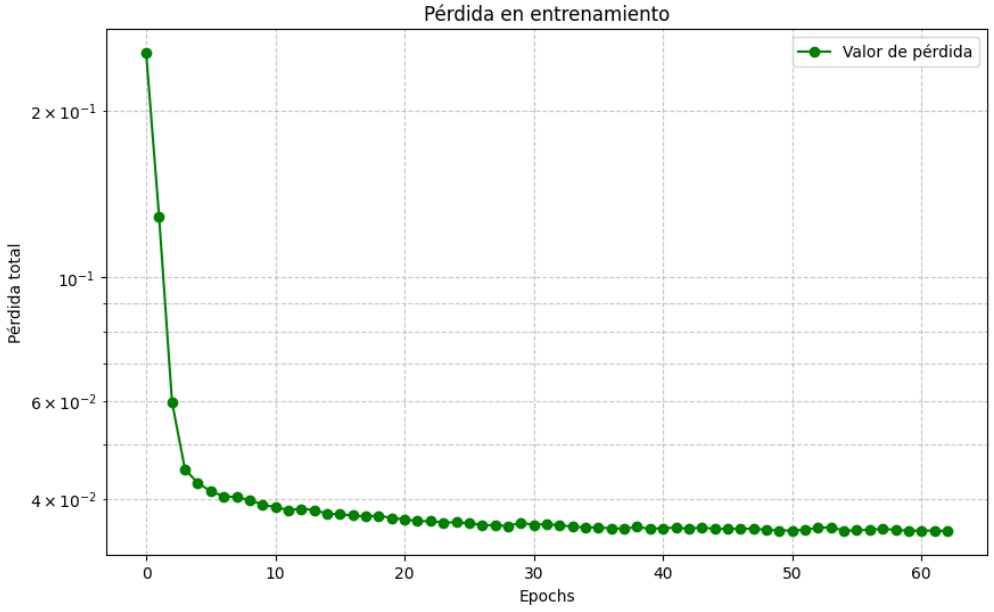

Figura 4.6: Evolución de la pérdida en la fase de entrenamiento del módulo de composición.

comprobar si el resultado de ambos módulos muestra un resultado natural y no tan sobreeditado como el que podría generar un usuario amateur. En la Tabla 4.9 se aprecian los resultados promedios de calcular la métrica NIQE en el conjunto de datos original, el resultado de la salida de ambos módulos por separado, y el resultado del *pipeline* completo usando ambos módulos, generando primero la imagen recortada con el módulo de composición y posteriormente tomando como entrada para el módulo de colorimetría dicha imagen recortada.

Observando los resultados de la métrica NIQE se puede apreciar que tanto en los conjuntos de datos del módulo de colorimetría como el *pipeline* completo usando ambos módulos se obtiene una mejoría, siendo mejor el módulo de colorimetría individualmente. En el caso del módulo de composición se observa que el resultado empeora. Tras obtener estos resultados se observa un claro caso de desajuste de dominio (*Domain Shift*). Comparando la métrica NIQE en el conjunto original frente a la salida del módulo de composición, con una diferencia de $\approx 0{,}3$ puntos, se puede verificar que la aproximación usada para generar el conjunto de datos usando modelos de difusión ha causado que la red presente un sesgo a la hora de predecir el recorte. Esto significa que la red aprendió a enfocar la atención en ciertas regiones de alta complejidad (texturas densas, detalles finos) o regiones muy específicas que el modelo de difusión consideraba importantes para

su *Ground Truth* sintético. Por otro lado, el buen resultado en los conjuntos de datos que incluyen la inferencia del módulo de colorimetría confirma que la red ha modificado los canales de color, contraste y brillo de la imagen de una manera que reduce la distancia estadística a las imágenes naturales. Esto sugiere que la red ha aprendido a corregir problemas de sub-exposición o mala saturación presentes en las imágenes de entrada, haciéndolas visualmente más agradables y plausibles, lo que se buscaba replicar con un modelo que automatizara la edición de fotografías siguiendo los mismos principios que un fotógrafo profesional.

La métrica BRISQUE (*Blind/Referenceless Image Spatial Quality Evaluator*) se basa en el modelado de coeficientes de contraste local normalizados en el dominio espacial. Esta métrica comparte la base teórica del Modelo CSS, pero su enfoque es distinto: se centra en identificar y cuantificar las distorsiones específicas que afectan la percepción humana. A diferencia de NIQE, que se enfoca en la naturalidad, BRISQUE está diseñado para detectar artefactos comunes introducidos por el procesamiento de imágenes, como el ruido, el desenfoque y los artefactos de compresión. BRISQUE mide la "limpieza" de la imagen, asegurando que el proceso de los distintos módulos no hayan dañado la estructura espacial de la imagen original. Al igual que para NIQE, en la Tabla 4.9 se aprecian los resultados promedios de calcular la métrica BRISQUE en los distintos conjuntos de datos.

Métrica	**Imagen Original (Sin procesar)**	**Módulo CropNet (Solo composición)**	**Módulo LUTNet (Solo color)**	**Sistema Completo (End-to-End)**
NIQE	5,94	6,21	**5.65**	5,86
BRISQUE	**38.32**	49,59	44,63	46,86

Tabla 4.9: Resultados de la métricas BRISQUE y NIQE en los distintos conjuntos de datos de salida.

En este caso se aprecia que la métrica propuesta ofrece un mejor resultado para el conjunto de datos original frente a la salida de los distintos módulos. Al igual que con NIQE, se observa que el módulo más perjudicado es el de composición mientras que el de colorimetría o el completo consiguen un resultado ligeramente menor. Respecto al módulo de colorimetría, a pesar de haber obtenido un mejor resultado con NIQE, la naturaleza de BRISQUE se basa en un Regresor de Vectores de Soporte (SVR) entrenado para detectar

distorsiones comunes (JPEG, *blurring*, ruido Gaussiano) a partir de estadísticas locales de bloques . Es muy sensible a irregularidades de alta frecuencia. La agresividad del módulo de colorimetría al manipular los píxeles (aunque sea por una buena causa perceptual) está introduciendo fallas estructurales. Mientras que el resultado con NIQE es excelente, BRISQUE detecta estas anomalías locales y las penaliza severamente, ya que son consideradas peores que las distorsiones fotográficas tradicionales. La métrica BRISQUE sube, indicando que, a nivel estructural, la imagen está más degradada.

4.5.4. Métricas de evaluación subjetiva: Mean Opinion Score (MOS)

Para validar la relevancia estética de los resultados desde una perspectiva humana, se ha realizado una evaluación cualitativa mediante el test *Mean Opinion Score* (MOS). Este análisis complementa las métricas objetivas (NIQE, BRISQUE) al capturar matices de armonía y atractivo visual que los modelos estadísticos suelen omitir.

El experimento se estructuró mediante un test ciego en el que un panel de evaluadores compuesto por 15 personas de distinta edad analizó un conjunto de 50 muestras. Para cada muestra, se presentaron de forma aleatoria la imagen original y la versión procesada por el sistema. Los evaluadores asignaron una puntuación basada en una escala Likert de 5 puntos (1: Pobre, 2: Mediocre, 3: Justa, 4: Buena, 5: Excelente), considerando los siguientes criterios:

- **Equilibrio Compositivo:** Evaluación del re-encuadre basado en el peso visual de los elementos.
- **Naturalidad Cromática:** Ausencia de artefactos o saturaciones irreales tras la aplicación de curvas.
- **Mejora Global:** Percepción general del valor añadido por el sistema de edición automática.

Los resultados obtenidos se presentan en la Tabla 4.10, desglosando el rendimiento por cada módulo del sistema.

El análisis de las puntuaciones obtenidas en el test *Mean Opinion Score* revela tres hallazgos fundamentales sobre la percepción humana del sistema.

- **Sinergia Estética** (Puntuación máxima en flujo completo): El flujo *end-to-end* obtuvo el MOS más elevado, superando la suma de los beneficios de los módulos

Configuración del Modelo	**MOS (Promedio)**	**Desviación Estándar (σ)**
Imagen Original (Sin procesar)	3.2	0.2
Módulo CropNet (Solo composición)	3.5	**0.5**
Módulo LUTNet (Solo color)	4	0.2
Sistema Completo (End-to-End)	**4.3**	0.1

Tabla 4.10: Resultados de la evaluación subjetiva MOS para las diferentes etapas del pipeline.

individuales. Esto sugiere que la percepción de "calidad profesional" por parte del usuario no depende de un solo factor, sino de la armonización entre una composición equilibrada y una colorimetría coherente. La corrección de color parece "validar" el nuevo encuadre propuesto, dando como resultado una imagen percibida como una obra terminada.

- **Consenso y Robustez** (σ mínima en el sistema completo): La baja desviación estándar (σ) en el sistema completo indica un alto grado de acuerdo entre los evaluadores. Mientras que las imágenes originales o editadas parcialmente generaron opiniones divididas, el resultado final del modelo fue aceptado de forma casi unánime como una mejora, lo que demuestra la robustez del sistema para satisfacer criterios estéticos generales.

- **Subjetividad de la Composición** (σ elevada en CropNet): El módulo de solo composición presentó la mayor varianza en las puntuaciones. Esto es coherente con la naturaleza de la fotografía: mientras que la corrección de un color "lavado" es un beneficio técnico casi objetivo, el re-encuadre de una escena entra en el terreno de la intención artística. Lo que un evaluador considera un "primer plano dinámico", otro puede percibirlo como un "encuadre demasiado cerrado", lo que explica la dispersión de las notas en esta etapa.

En conclusión, los datos demuestran que, si bien la composición es el elemento más subjetivo del *pipeline*, su integración con un ajuste colorimétrico preciso actúa como un factor estabilizador que eleva significativamente la percepción de calidad general y el consenso entre usuarios.

4.5.5. Eficiencia temporal (*Throughput*)

El rendimiento en tiempo real se evaluó midiendo el tiempo promedio de inferencia por imagen (τ_{inf}), crucial para aplicaciones prácticas, en un conjunto de *test* de 100 imágenes.

Para el módulo de composición se obtuvo un tiempo promedio de $\tau_{comp} \approx 1{,}12$ segundos mientras que en el caso del módulo de colorimetría se obtuvo un tiempo promedio de $\tau_{color} \approx 2{,}06$ segundos. Teniendo en cuenta ambos tiempos se obtiene un tiempo promedio total de $\tau_{Total} \approx 3{,}18$ segundos por imagen. Este tiempo sitúa al *pipeline* como adecuado para el procesamiento por lotes / procesamiento en tiempo casi real.

4.5.6. Análisis visual de los resultados

La evaluación de la calidad de imagen en tareas de mejora y estilización presenta un desafío inherente: la divergencia entre las puntuaciones generadas por métricas ciegas (*No-Reference Image Quality Assessment, NR-IQA*) y la valoración estética o perceptual humana. El objetivo del presente trabajo fue emular el proceso de edición fotográfica profesional, un proceso que prioriza el impacto visual y la estética sobre la fidelidad estadística con la imagen original. Al examinar las métricas ciegas (NIQE y BRISQUE) en la Figura 4.7 a través de las diferentes etapas de la *pipeline*, se observa una paradoja crítica. La métrica NIQE, que mide la distancia a un modelo estadístico de imágenes naturales, frecuentemente es más alto en la imagen final (Resultado Final) que en la imagen inicial (Original). Esto implica, según la métrica, una pérdida de naturalidad estadística. En el caso de BRISQUE, que detecta artefactos y distorsiones espaciales, muestra un incremento significativo en la mayoría de los casos de mejora. Este aumento indica que la red de mejora de colorimetría introduce irregularidades estadísticas de alta frecuencia, interpretadas como ruido o artefactos de procesamiento por el algoritmo. Esta degradación métrica es el coste computacional de la estética.

A pesar de las puntuaciones menos favorables de NIQE y BRISQUE en el Resultado Final, el análisis cualitativo y visual demuestra que la red ha cumplido exitosamente su objetivo perceptual. La red aprende a manipular la colorimetría, el contraste y la saturación de manera que se logre un resultado visualmente más impactante y estético, asemejándose a una fotografía tratada por un profesional. El incremento de contraste y la saturación selectiva (propios de la edición fotográfica) fuerzan las distribuciones de píxeles lejos del Modelo Gaussiano Multivariado (MVG) en el que se basa NIQE. La red no está bus-

cando “naturalidad promedio” sino “estética optimizada”. Por ello, el valor de la métrica aumenta. En el caso de BRISQUE, el valor notablemente más alto se debe a la agresividad necesaria del módulo de colorimetría para producir cambios notables. BRISQUE penaliza la alteración de la relación estadística entre vecinos, que es precisamente lo que ocurre cuando se aplica una curva de contraste fuerte o una corrección de color puntual. La métrica confunde el detalle realzado/saturado con ruido de síntesis.

En conclusión, la discordancia entre los resultados métricos y la calidad visual percibida valida la premisa central del trabajo: las métricas ciegas de propósito general no son indicadores fiables de la calidad estética o el éxito de una tarea de estilización artística. El Resultado Final es superior en términos de impacto visual y alineación con el *Ground Truth* perceptual (el objetivo de edición fotográfica), justificando el compromiso de sacrificar la fidelidad estadística (alto BRISQUE) a cambio de la ganancia estética, logrando así el objetivo principal del proyecto.

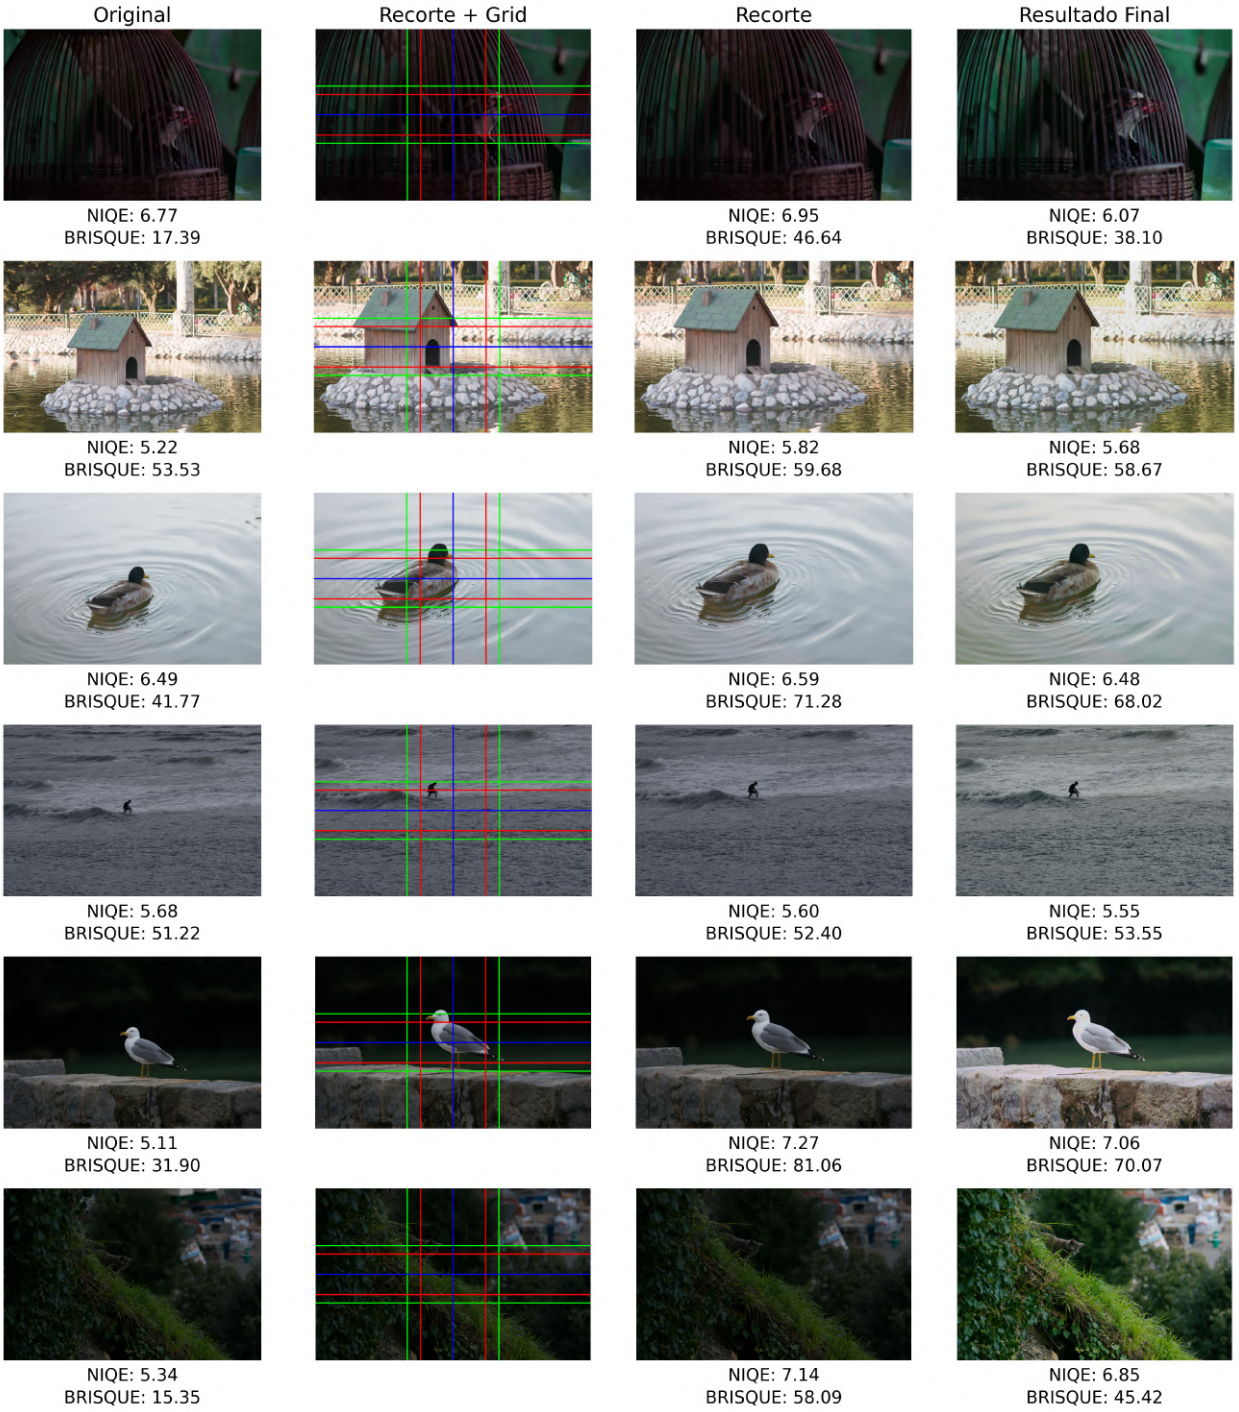

Figura 4.7: Resultado del *pipeline* de inferencia completo y representación visual de las guías usadas como pérdidas en el módulo de composición. En verde regla de los tercios, en rojo proporción áurea y en azul simetría horizontal y vertical.

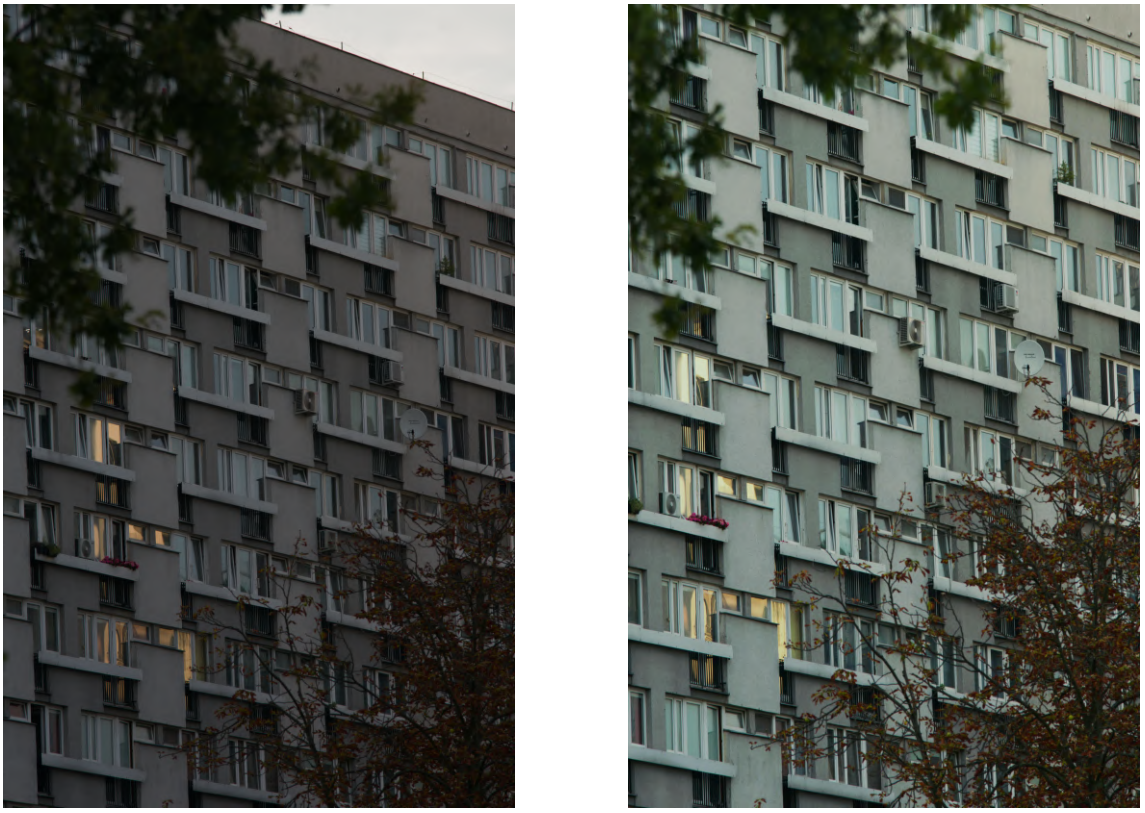

(a) Imagen Original.

(b) Resultado de la Inferencia Final.

Figura 4.8: Comparación visual entre la imagen de entrada y el resultado final. La Figura a muestra la imagen capturada y la Figura b el resultado optimizado.

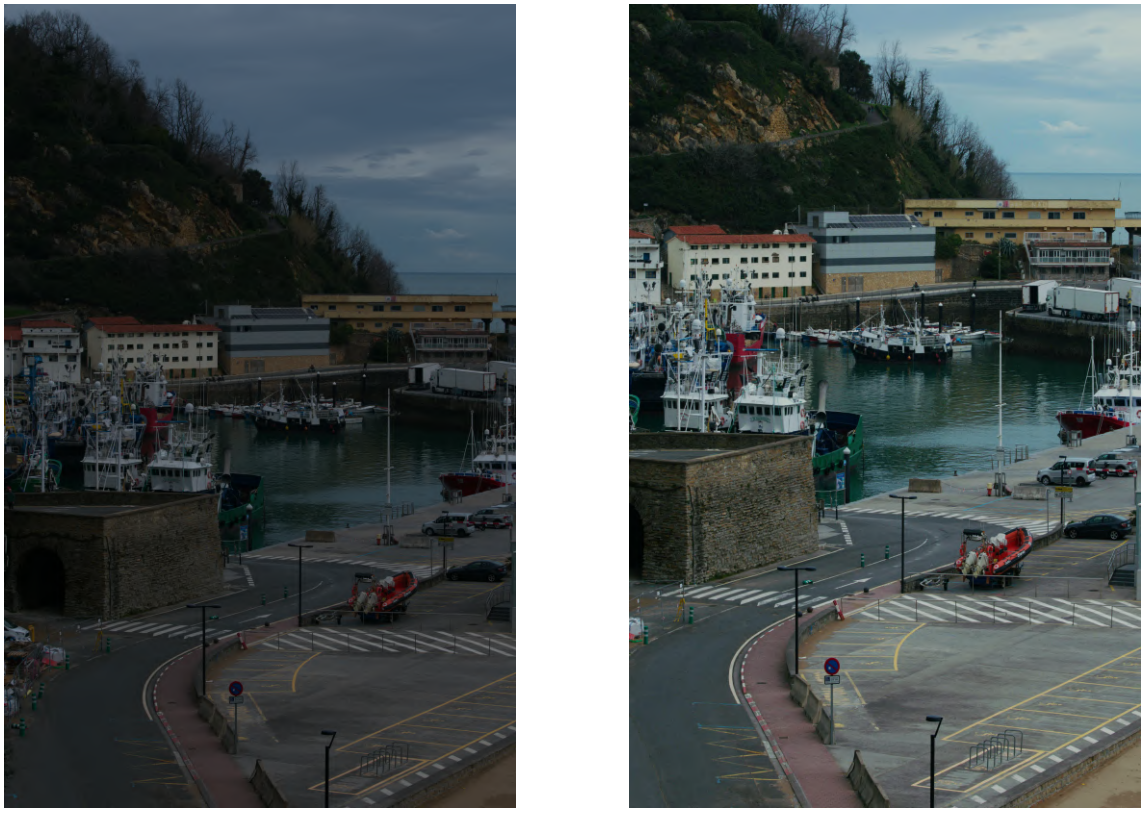

(a) Imagen Original.

(b) Resultado de la Inferencia Final.

Figura 4.9: Comparación visual entre la imagen de entrada y el resultado final. La Figura a muestra la imagen capturada y la Figura b el resultado optimizado.

5. Conclusiones y trabajo futuro

5.1. Conclusiones del proyecto

El objetivo principal de este proyecto, emular el proceso de estilización fotográfica profesional mediante redes neuronales convolucionales, se ha alcanzado con éxito.

El modelo de mejora propuesto presenta un flujo completo que recorta la imagen siguiendo criterios estéticos que usan profesionales de la fotografía y ajusta la colorimetría semánticamente usando curvas complejas que se adaptan a los resultados que podemos ver en páginas importantes como Unsplash.

Respecto a la comparación con otros trabajos en el estado del arte, este proyecto representa una evolución hacia la eficiencia y la autonomía, simplificando drásticamente el flujo de trabajo sin perder la esencia del aprendizaje por *outpainting*. A diferencia de los trabajos estudiados como (Yang y cols., 2022), que depende de procesos externos pesados como generar máscaras de segmentación para cada sujeto y usar complejos mecanismos de atención, la arquitectura presentada en 4.4.2 apuesta por una regresión directa y ligera. Esta es una mejora significativa en términos de velocidad de inferencia y facilidad de despliegue: al eliminar la necesidad de una máscara de entrada, el modelo es capaz de "entender" la composición de forma holística y autónoma, permitiendo que el sistema tome decisiones de encuadre instantáneas en dispositivos con menos recursos, sin la fricción de tener que identificar y aislar cada objeto de la imagen previamente. En el caso del módulo de colorimetría, el sistema mejora los métodos tradicionales, como los estudiados en la sección 2.3.1, al pasar de un ajuste puramente estadístico a uno perceptual y selectivo. Mientras que otros modelos aplican cambios globales que pueden distorsionar los tonos naturales o perder detalles en las sombras, este módulo actúa como un colorista experto que sabe distinguir entre la iluminación y el color real. Al trabajar en espacios de color avanzados (Lab y HSV), el sistema es capaz de proteger la fidelidad de los tonos (como la piel o el cielo) y rescatar información en zonas críticas de luz y sombra de forma independiente. El resultado es una imagen que no solo tiene un mejor contraste, sino que mantiene una coherencia visual y una naturalidad que los algoritmos convencionales suelen sacrificar.

Uno de los hallazgos más significativos del trabajo es la disociación sistemática observada entre las métricas de calidad de imagen ciegas (NIQE y BRISQUE) y la calidad estética percibida.

Se concluye que las métricas NIQE y BRISQUE son inadecuadas para evaluar modelos cuyo objetivo primario es la estilización o la mejora estética. El aumento de las puntuaciones de BRISQUE y, en ocasiones, de NIQE, no indica una degradación de la calidad, sino que refleja la agresividad estadística de las transformaciones necesarias para lograr el impacto visual deseado (ej., aumento de contraste, saturación selectiva), algo que los algoritmos interpretan erróneamente como artefactos o desviación de la "imagen natural promedio".

La validación final del modelo se sustenta en la evaluación visual, confirmando que, para tareas orientadas a la experiencia humana, la percepción es la métrica de calidad más relevante.

El sistema demuestra ser robusto en la mejora de la colorimetría en diversas condiciones de iluminación y escena. No obstante, su limitación principal reside en la complejidad computacional inherente al uso de recortes, lo que implica un mayor tiempo de inferencia en comparación con redes de mejora global puras.

5.2. Líneas de trabajo futuro

Dado el estudio realizado en los trabajos relacionados y los objetivos conseguidos con este proyecto, surgen varias líneas de investigación futuras que podrían tomar el modelo actual y aplicarlo a distintos problemas o incluso mejorarlo de cara a hacerlo más versátil para un usuario final.

5.2.1. Optimización y eficiencia computacional

La principal línea de futuro se centra en aumentar la eficiencia de la inferencia, manteniendo la calidad.

Se podría integrar una detección de Regiones de Interés (*RoI*) con el objetivo de reemplazar el recorte sistemático por un módulo de Atención o Detección de Regiones de Interés basado en visión artificial. Esto permitiría aplicar la mejora de alta resolución solo donde es estrictamente necesario, reduciendo drásticamente la latencia de inferencia.

De cara a implementar el modelo en dispositivos móviles o sistemas que no cuenten con una alta capacidad de cómputo se podría optar por una destilación del modelo. Explorando técnicas de destilación de conocimiento (*Knowledge Distillation*) se podría llegar a crear una versión más ligera y rápida de la red final de estilización que pueda ser implementada

en dispositivos *edge* (ej., en una aplicación móvil), manteniendo el rendimiento estético del modelo más grande.

5.2.2. Expansión y validación del dominio estético

Se podría implementar y validar el modelo contra métricas de calidad de imagen basadas en percepción humana (ej., LPIPS o FID), que son más adecuadas para evaluar la fidelidad perceptiva y estética, ofreciendo una justificación cuantitativa más sólida que la proporcionada por NIQE y BRISQUE. Esto haría que la puntuación fuera más fiel a la realidad y que concordara con el principal motivo del proyecto, hacer un modelo que automatice la edición de fotografías de la misma manera que haría un profesional, sin tener en cuenta métricas basadas en la naturalidad de una imagen.

Se podría ampliar la capacidad de la red para permitir la estilización condicional, donde el usuario pueda elegir entre varios estilos predefinidos (ej., "Baja Contraste Urbano", "Saturación de Paisaje"), añadiendo una entrada de control al modelo. A pesar de la existencia de herramientas que aplican filtros basados en estilos, el añadir esta herramienta al módulo de colorimetría permitiría que la herramienta fuera mucho más versátil y usable por un usuario final.

5.2.3. Aplicación a secuencias de vídeo

Dada la eficiencia del modelo y su rendimiento a la hora de inferir resultados en un bajo tiempo, se podría daptar el modelo a la edición de secuencias de vídeo, con un enfoque en garantizar la coherencia temporal de la estilización entre fotogramas consecutivos. Esto requeriría añadir un módulo recurrente o temporal al final de la arquitectura para evitar el "parpadeo" (*flickering*) visual en el resultado.

Referencias

Adobe HelpX. (2025). *Lightroom mobile faq.* Descargado de https://helpx.adobe.com/mobile-apps/help/lightroom-mobile-faq.html?utm_source=chatgpt.com (Accessed: 2025-10-12)

Arjovsky, M., Chintala, S., y Bottou, L. (2017). *Wasserstein gan.* Descargado de https://arxiv.org/abs/1701.07875

Deng, Y., Loy, C. C., y Tang, X. (2017). Aesthetic-driven image enhancement by adversarial learning. *CoRR*, *abs/1707.05251*. Descargado de http://arxiv.org/abs/1707.05251

Doran, G. T. (1981). There's a s.m.a.r.t. way to write management's goals and objectives. *Management Review*, *70*(11), 35–36. (Criterios SMART)

Freeman, M. (2007). *The photographer's eye: Composition and design for better digital photos.* Burlington, MA: Focal Press.

Hand, M. (2017). Visuality in social media: Sharing, seeing, and visibility. *Media, Culture & Society*, *39*(4), 520–535. doi: 10.1177/0163443716682072

He, K., Zhang, X., Ren, S., y Sun, J. (2015). Deep residual learning for image recognition. *CoRR*, *abs/1512.03385*. Descargado de http://arxiv.org/abs/1512.03385

Highfield, T., y Leaver, T. (2016). *Instagram: Visual social media cultures.* Cambridge, UK: Polity Press.

Hong, J., Yuan, L., Gharbi, M., Fisher, M., y Fatahalian, K. (2024). *Learning subject-aware cropping by outpainting professional photos.* Descargado de https://arxiv.org/abs/2312.12080

Ivanov, S. (2017, 20 de noviembre). *Differential learning rates.* Blog post, Slav's blog. Descargado de https://blog.slavv.com/differential-learning-rates-59eff5209a4f (Accedido el 11 de noviembre de 2025)

Jolicoeur-Martineau, A. (2018). *The relativistic discriminator: a key element missing from standard gan.* Descargado de https://arxiv.org/abs/1807.00734

Lee, S., y Kwon, H. (2021). Ai-assisted image enhancement in consumer photo-editing applications. *IEEE Access*, *9*, 117345–117359. doi: 10.1109/ACCESS.2021.3106632

Madgicx Blog. (2025). *How to edit an instagram post.* Descargado de https://madgicx.com/blog/edit-instagram-post?utm_source=chatgpt.com (Accessed: 2025-10-12)

Mai, L., Le, H., Niu, Y., y Liu, F. (2011). Rule of thirds detection from photograph. En *2011 ieee international symposium on multimedia* (p. 91-96). doi: 10.1109/ISM.2011.23

Mejova, Y., Weber, I., y Fernandes Silva, M. (2018). Pinterest: Image content and social dynamics. *ACM Transactions on the Web*, *12*(4), 1–27. doi: 10.1145/3185048

Moran, S., McDonagh, S., y Slabaugh, G. (2020). *Curl: Neural curve layers for global image enhancement.* Descargado de `https://arxiv.org/abs/1911.13175`

Ni, Z., Yang, W., Wang, S., Ma, L., y Kwong, S. (2020). Towards unsupervised deep image enhancement with generative adversarial network. *CoRR*, *abs/2012.15020*. Descargado de `https://arxiv.org/abs/2012.15020`

Reddit: r/snapseed. (2025). *Disappointed with the new snapseed update.* Descargado de `https://www.reddit.com/r/snapseed/comments/1lperdc/disappointed_with_the_new_update/?utm_source=chatgpt.com` (Accessed: 2025-10-12)

Reddit: r/vsco. (2025). *Posted almost 500 photos to vsco in the last month.* Descargado de `https://www.reddit.com/r/vsco/comments/19e6qso/i_posted_almost_500_photos_to_vsco_in_the_last/?utm_source=chatgpt.com` (Accessed: 2025-10-12)

Ren, S., He, K., Girshick, R., y Sun, J. (2016). *Faster r-cnn: Towards real-time object detection with region proposal networks.* Descargado de `https://arxiv.org/abs/1506.01497`

Rombach, R., Blattmann, A., Lorenz, D., Esser, P., y Ommer, B. (2022). High-resolution image synthesis with latent diffusion models. En *Proceedings of the ieee/cvf conference on computer vision and pattern recognition (cvpr)* (pp. 10684–10695). Descargado de `https://arxiv.org/abs/2112.10752`

RunwayML. (2022). *Stable diffusion inpainting.* `https://huggingface.co/runwayml/stable-diffusion-inpainting`. (Model card. Available from Hugging Face)

Serrano-Lozano, D., Herranz, L., Brown, M. S., y Vazquez-Corral, J. (2024). *Namedcurves: Learned image enhancement via color naming.* Descargado de `https://arxiv.org/abs/2407.09892`

Simonyan, K., y Zisserman, A. (2015). *Very deep convolutional networks for large-scale image recognition.* Descargado de `https://arxiv.org/abs/1409.1556`

Snapseed QRCodes. (2025). *Snapseed pros and cons.* Descargado de `https://snapseedqrcodes.net/snapseed-pros-and-cons/?utm_source=chatgpt.com`

(Accessed: 2025-10-12)

Song, Y., Qian, H., y Du, X. (2021). Starenhancer: Learning real-time and style-aware image enhancement. *CoRR*, *abs/2107.12898*. Descargado de `https://arxiv.org/abs/2107.12898`

VSCO Support. (2025). *Vsco parent guide.* Descargado de `https://support.vsco.co/hc/en-us/articles/18444811876109-VSCO-Parent-Guide?utm_source=chatgpt.com` (Accessed: 2025-10-12)

Yang, G.-Y., Zhou, W.-Y., Cai, Y., Zhang, S.-H., y Zhang, F.-L. (2022). Focusing on your subject: Deep subject-aware image composition recommendation networks. *Computational Visual Media*, *9*(1), 87–107. doi: 10.1007/s41095-021-0263-3

A. Apendices